DOCUMENTAÇÃO DE PROJETO DE SOFTWARE

PLATAFORMA NACIONAL DE PROSPECÇÃO DE FARMÁCIAS

Arquitetura de software, web scraping, requisitos e modelagem de dados

Documento	Especificação técnico-funcional
Versão	1.5 - Multiplas fontes; Supabase; sem Docker
Banco de dados	Supabase (PostgreSQL gerenciado)
Data	23 de outubro de 2026

Projeto em fase de especificação. Requisitos, metas e decisões identificadas como propostas ou pendentes exigem validação antes da implementação e da operação comercial.

SUMÁRIO

1. Apresentação e controle do documento 3

2. Objetivos, indicadores e fronteiras do sistema 5

3. Arquitetura da solução 7

4. Levantamento de requisitos funcionais 16

5. Requisitos não funcionais 23

6. Regras de negócio e decisão de qualidade 26

7. Especificação de coleta e web scraping 28

8. Modelo de dados Supabase / PostgreSQL 39

9. Contratos de API e navegação do painel 44

10. Segurança, privacidade e conformidade 48

11. Testes, qualidade e homologação 49

12. Planejamento de execução 53

13. Operação, monitoramento e resposta a incidentes 55

14. Riscos e decisões abertas 56

15. Parecer técnico crítico sobre a arquitetura 58

16. Referências, rastreabilidade e histórico 60

PLATAFORMA NACIONAL DE PROSPECÇÃO DE FARMÁCIAS

Documento de projeto de software e especificação técnico-funcional
Versão: 1.5 - aquisição mult fontes, cadastro permanente por origem permitida, consulta Google Places separada, operação manual/automática e infraestrutura sem Docker; proposta para aprovação e início da implementação
Data: 23 de outubro de 2026
Base de referência: “Projeto revisado: plataforma nacional de prospecção de farmácias” (documento fornecido pelo solicitante, 23/10/2026).
Banco de dados escolhido: Supabase (PostgreSQL gerenciado).
Situação: arquitetura proposta; funcionalidades ainda não implementadas ou homologadas.

> **Controle de versão:** este documento transforma o plano de referência em especificação de implementação. Preserva a proposta de base mestre da Receita, enriquecimento por fontes autorizadas, procedência dos contatos e separação entre coleta e comercial. Acrescenta requisitos verificáveis, arquitetura detalhada com Supabase, contratos de integração, modelo lógico ampliado e critérios de implantação. A versão 1.2 especificou duas modalidades de acionamento de coletas (manual pelo painel e automática por agenda do sistema operacional), com o mesmo motor de jobs, controle de concorrência e auditoria. A versão 1.3 separou Google Business Profile e Google Places. A versão 1.5 acrescenta um catálogo mult fontes com termos de uso, regras de persistência por campo, conectores independentes, gates de publicação, fontes administrativas e checagens de regularidade; mantém o objetivo da versão 1.4: **encontrar farmácias e consultar contatos no Google Maps**, por APIs oficiais Places, sem gestão de perfis de terceiros. Google Places é uma fonte de descoberta/consulta referenciada por `place_id`, não uma autorização para replicar seus contatos em uma base persistente de CRM. Valores, prioridades e metas assinalados como *propostos* requerem validação do responsável pelo produto.

1. Apresentação e controle do documento

1.1 Finalidade

Servir como referência para iniciar a construção de uma aplicação interna de prospecção B2B voltada a estabelecimentos farmacêuticos no Brasil. Reúne definição de produto, arquitetura, requisitos funcionais (RF), requisitos não funcionais (RNF), regras de negócio (RN), modelos de informação, fluxos de dados, diretrizes de scraping, APIs, segurança, testes, indicadores e entregas. É uma especificação de construção, não uma afirmação de que os controles já estejam em produção.

1.2 Escopo, limites e premissas

- Abrangência alvo: Brasil, com implantação progressiva por unidade federativa e município. A UF do piloto permanece **a definir**.

- Universo cadastral proposto: estabelecimentos com situação cadastral ativa e CNAE principal 4771-7/01 (sem manipulação), 4771-7/02 (com manipulação) e 4771-7/03 (homeopáticos). A inclusão de 4771-7/04 (veterinários) depende de aprovação de escopo.
- Identificador principal de estabelecimento: CNPJ completo de 14 dígitos. A raiz do CNPJ serve para agrupamento empresarial, não para fundir filiais.
- Dados: informações cadastrais de empresas e canais de contato empresariais, com classificação de eventual dado pessoal. Não coletar dados de pacientes, clientes, CPFs, sócios ou responsáveis técnicos como objeto da prospecção.
- O sistema **não** terá envio automático de e-mail, ligações ou WhatsApp no MVP. Exportar ou consultar um canal não equivale a permissão para abordar seu titular.
- Os fluxos de armazenamento, acesso e exportação dependem de validação de tratamento de dados e de termos de uso das fontes.
- Supabase gerencia o PostgreSQL, Auth e Storage; **não executa** os browsers e spiders. Os workers de coleta rodam em serviço Python fora da plataforma.
- O painel inicial inclui um CRM leve (status, responsável, observações e histórico). Integração com CRM corporativo é evolução condicionada à existência e ao contrato do CRM.
- **Modelo mult fontes definido:** a aplicação deverá combinar base oficial de CNPJ, fontes públicas complementares, sites e localizadores autorizados, cadastro comercial informado diretamente, e fornecedores B2B licenciados, com habilitação por fonte. O Google Places permanece um recurso separado de consulta e não alimenta diretamente o cadastro comercial persistente.
- **Objetivo Google confirmado:** localizar farmácias e consultar os contatos comerciais apresentados no Google Maps. Usar **Google Places API (New)**, com Text Search, Nearby Search e Place Details; nunca a API Google Business Profile para consultar terceiros. O sistema poderá reter `place_id` e oferecer consulta contextual de dados sujeitos às políticas e atribuições da Google Maps Platform. A montagem de uma base permanente de telefones/sites/endereço extraídos exclusivamente de Places **não está autorizada por padrão**; informações persistidas no Supabase deverão ter fonte própria e direito de reutilização. Integração depende da aprovação de orçamento, termos e elegibilidade.

1.3 Classificação das decisões

Marca	Significado	Exemplo
Definido	Requisito presente no documento-base ou decisão explícita	Supabase; foco em farmácias; scraping necessário
Proposto	Escolha técnica recomendada, sujeita a avaliação do time	FastAPI; processos Python com `venv` e agendamento do sistema operacional; metas de desempenho
Pendente	Afeta escopo, conformidade ou custo; requer decisão formal	UF do piloto; canais de abordagem; orçamento de APIs

1.4 Partes interessadas e responsabilidades

Papel	Responsabilidade	Situação
Responsável pelo produto / negócio	Aprovar prioridades, campos e regras comerciais	Nome a designar
Desenvolvimento backend e dados	Ingestão, scrapers, banco, API e deploy	Nome a designar
Desenvolvimento frontend	Experiência do painel e integração com API	Nome a designar
QA	Estratégia de testes, evidências, homologação e critérios de aceite	Nome a designar
Operação comercial	Validar utilidade, precisão e tratamento de leads	Nome a designar
Responsável jurídico/LGPD	Bases legais, políticas por fonte, opt-out, retenção	Nome a designar
Administrador de infraestrutura	Segredos, observabilidade, backup, custos e incidentes	Nome a designar

2. Objetivos, indicadores e fronteiras do sistema

2.1 Problema de negócio

A descoberta manual de farmácias e a manutenção de listas comerciais são lentas, geram duplicidade e não mostram claramente de onde vieram os contatos. É necessário criar um cadastro nacional incremental, usando dados oficiais para cobertura e crawling autorizado para obter informações que a base cadastral não possui ou não confirma.

2.2 Objetivos do produto

1. Manter base mestre rastreável de estabelecimentos elegíveis ao público-alvo.
2. Identificar sites oficiais, importar bases públicas complementares e coletar contatos empresariais publicados de forma permitida.
3. Evitar misturar informação observada, inferência automática e confirmação efetiva.
4. Consolidar contatos com origem, data, classificação e grau de confiança.
5. Oferecer ao comercial consulta, filtros, distribuição, status, observações e exportação controlada.
6. Detectar alterações de layouts, falhas de coleta e desatualização dos dados.
7. Operar com controles de acesso, trilha de auditoria, supressão e capacidade de recuperação.

8. Permitir várias fontes de prospecção com regras independentes de licenciamento, armazenamento, exportação e confiabilidade; nenhum dado entra na base mestre sem origem comprovável.

2.3 Indicadores e metas iniciais

Indicador	Definição operacional	Meta/condição inicial
Cobertura cadastral	Ativos elegíveis importados / ativos elegíveis na versão de referência	Alvo 100% do recorte validado, após reconciliação
Cobertura com site confirmado	Estabelecimentos com domínio confirmado / elegíveis	Medir baseline do piloto
Cobertura com contato verificado	Elegíveis com ao menos um contato confirmado / elegíveis	Meta após baseline; não inventar percentual
Precisão do vínculo site-CNPJ	Matches corretos em amostra humana estratificada	Meta proposta >=95% no piloto
Precisão de contato exportável	Contatos corretamente atribuídos em amostra rotulada	Meta proposta >=90%; por tipo de contato
Taxa de duplicidade	Duplicados comprovados / registros amostrados	Meta proposta <1%
Taxa de erro de coleta	Jobs com falha por fonte / jobs elegíveis	Meta proposta <5%, desagregada por causa
Frescor	Contatos reavaliados em até 90 dias	Proposta, sujeita à relevância comercial
Tempo de consulta	Percentil 95 de GET paginado nas condições de teste	Proposta <=2 s para 50 registros
Integridade comercial	Reprocessamentos que apagam status/observações do vendedor	Obrigatoriamente 0

Interpretação: verificação de sintaxe de e-mail, MX, padrão telefônico ou HTTP 200 **não** comprova, isoladamente, que o contato pertence à farmácia, está ativo ou autoriza abordagem.

2.4 Dentro e fora do escopo

No escopo: cadastro nacional, cargas periódicas, descoberta de sites, spiders por fonte permitida, enriquecimento de contatos, evidências, normalização, revisão humana de casos ambíguos, base consolidada no Supabase, API, painel comercial mínimo, **início manual de coletas pelo painel e início automático por agendamento configurável**, exportações e auditoria. **Integração Google solicitada pelo negócio:** busca de farmácias via Places API com consulta contextual de telefones e sites, referenciada por `place_id`, com orçamento e limites; conteúdo restrito não é promovido automaticamente ao cadastro comercial persistente.

Fora do MVP: automação de mensagens, validação de números por chamadas, scraping de redes sociais em violação de termos, contorno de CAPTCHA/bloqueios, compra de bases sem procedência, inteligência artificial para decisão automática sobre pessoa física, CRM completo de funil de vendas e mapa geográfico avançado. Também ficam fora do MVP o gerenciamento de perfis Google Business Profile, o scraping de páginas do Google Maps e a construção de cadastro permanente de leads com dados restritos da Places API. O módulo Places poderá ser pilotado após aprovação técnica, financeira e jurídica.

3. Arquitetura da solução

3.1 Visão lógica de componentes

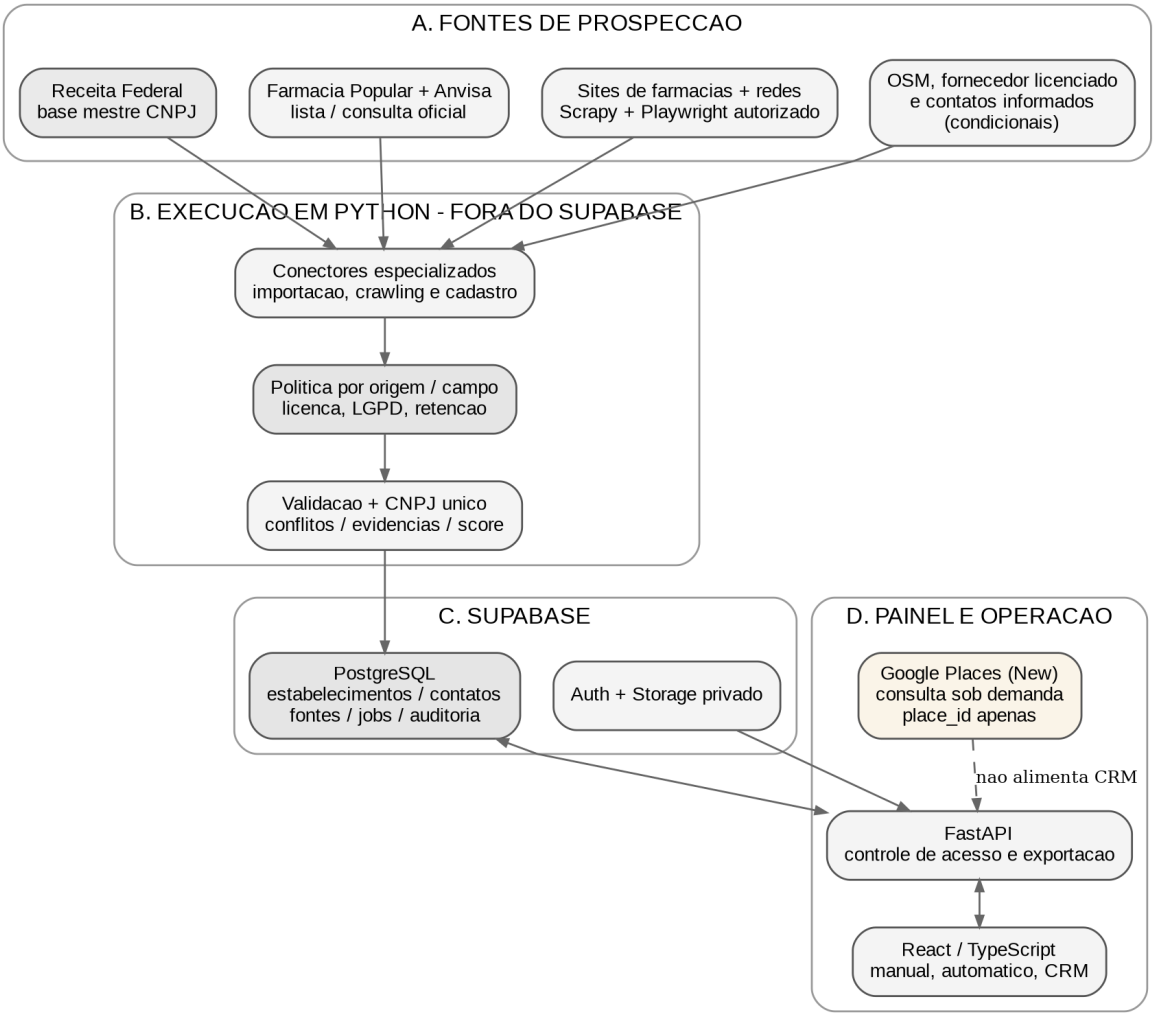


Figura 1 - Arquitetura mult fontes da plataforma

Legenda de responsabilidades: a Receita Federal é o cadastro mestre; Farmácia Popular, Anvisa (consulta, quando permitido), bases regionais autorizadas, OpenStreetMap (ODbL), sites institucionais, localizadores, contatos informados pela própria empresa e fornecedores com contrato podem funcionar como conectores independentes. Cada conector possui políti-

ca de licença e só libera campos cuja persistência esteja autorizada. Fontes oficiais e websites autorizados alimentam workers Python. A Google Places API oferece descoberta de estabelecimentos e apresentação pontual de dados, fora do motor Scrapy; a ligação à base própria ocorre apenas via `place_id` e regras de correspondência, sem importação automática de conteúdo restrito. Esses workers extraem, normalizam e persistem em esquemas internos do PostgreSQL/Supabase. A FastAPI lê e altera apenas o que sua função permite; o painel React não possui credenciais administrativas do banco. Supabase Auth autentica usuários, e Storage guarda evidências permitidas em bucket privado.

3.2 Pipeline de ponta a ponta

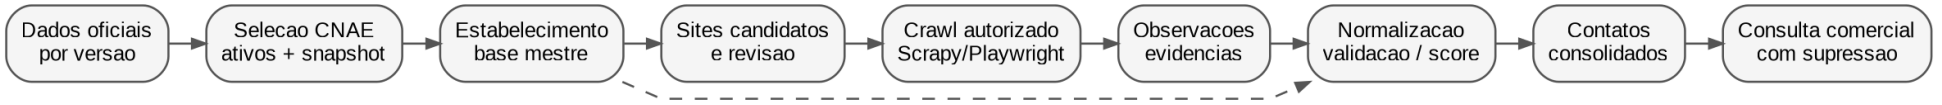


Figura 2 - Pipeline de ingestão, crawling e consolidação

Fluxo oficial: baixar manifesto e arquivos da Receita, conferir layout/integridade, processar em disco temporário ou armazenamento adequado, filtrar o recorte elegível, carregar staging e promover para o cadastro mestre.

Fluxo mult fontes: cada conector ativo recebe uma partição e uma política de uso; a importação de arquivos, o crawling permitido e a entrada manual entram em observações separadas. Antes da publicação, validar licença/uso, fonte, data, CNPJ, duplicidade, consentimento/base legal quando aplicável e supressão. **Fluxo de scraping:** descobrir URL candidata por fontes independentes autorizadas, confirmar associação ao estabelecimento, criar job, extrair conteúdo relevante, guardar observações e evidências, normalizar e resolver em contato consolidado. Nenhum campo Google Places pode ser recopiado como se tivesse outra origem.

Publicação: a camada comercial acessa uma visão consolidada e filtrada pelas regras de acesso, supressão, qualidade e canal. A coleta não altera os campos de gestão comercial.

3.3 Responsabilidades e fronteiras

Componente	Responsabilidade	Não deve fazer
Importador Receita	Versão, filtro, staging, snapshot e reconciliação	Fazer outreach ou reescrever status comercial
Conectores complementares	Ingerir listagens públicas autorizadas, datasets contratados e confirmações comerciais com procedência	Presumir que um conjunto público autoriza qualquer redistribuição
Motor de políticas por origem	Definir se o campo pode ser guardado, mostrado ou exportado e sua retenção	Trocar rótulo de origem para contornar termos externos
Descoberta	Levantar domínios candidatos e indícios de associação	Tratar domínio candidato como confirmado automaticamente
Spider Scrapy	Rastrear páginas permitidas com limites de domínio	Acessar caminhos vedados ou burlar bloqueios
Playwright	Renderizar contatos cujo DOM depende de JavaScript	Substituir requisição HTTP simples em toda URL
Google Places API (condicional)	Buscar farmácias de terceiros por termo/área, retornar IDs e consultar dados contextuais com atribuição	Persistir ou exportar conteúdo restrito como diretório permanente de prospecção
Places Insights (evolução opcional)	Identificar oportunidades por região no Brasil através do BigQuery, se contratado	Supor acesso livre ou irrestrito a nomes e contatos para armazenamento no CRM
Normalizador e resolvedor	Transformar observações em contatos canônicos	Inventar confirmação de contato sem evidência
Worker de jobs	Reservar tarefas, checkpoint, retry e registrar execução	Receber chamadas HTTP da interface como processo bloqueante

Componente	Responsabilidade	Não deve fazer
PostgreSQL/Supabase	Integridade, armazenamento relacional, histórico	Ser usado como depósito ilimitado de HTML e ZIPs enormes
Storage privado	Guardar arquivos permitidos com ciclo de retenção	Servir HTML e evidências publicamente
FastAPI	Autorização, orquestração lógica, consultas e exportações	Executar browser no processo de requisição
Painel React	Operação comercial e visibilidade de coletas	Acessar segredos administrativos

3.4 Comunicação, implantação e ambientes

- **Desenvolvimento:** Python instalado diretamente na máquina, dependências isoladas em ambiente virtual (`python -m venv .venv`), frontend executado com Node.js/Vite e projeto Supabase de desenvolvimento separado. Não conectar testes automatizados ao projeto de produção.
- **Homologação:** ambiente lógico distinto, configuração própria por variáveis de ambiente, conjunto reduzido de dados e fontes de teste e políticas de acesso equivalentes às de produção. A execução também será sem contêineres.
- **Produção:** frontend React publicado como aplicação estática; FastAPI executada como processo Python independente; coletores Scrapy/Playwright e importador executados por comandos Python separados, em máquina ou servidor compatível com seus requisitos de CPU, RAM, armazenamento e conectividade. Supabase permanece gerenciado e remoto.
- **Gerenciamento de processos:** em Linux, usar `systemd` para manter FastAPI e worker supervisionados, e `cron` ou `systemd timers` para iniciar periodicamente o comando leve de conferência de agendas (`scheduler tick`); em Windows, usar o Agendador de Tarefas para o mesmo comando e processo supervisionado para API e worker. **O agendador do sistema operacional apenas verifica agendas vencidas e insere jobs no Supabase; não executa o spider dentro da API ou a cada clique no painel.**
- **Pré-requisito de operação:** é necessário ao menos um ambiente capaz de executar Python e os navegadores do Playwright nos horários planejados. Caso haja somente um computador local, as coletas ocorrerão quando ele estiver ligado e conectado; disponibilidade contínua e cobertura nacional não devem ser assumidas.
- **Conexão ao banco:** backend persistente em conexão direta quando a rede suportar ou via pooler de sessão; migrações e operações SQL nativas em conexão compatível. Evitar pooler de transação para `COPY`, recursos de sessão e prepared statements sem avaliação específica.
- **Segregação:** schemas `ingest`, `core`, `coleta`, `comercial`, `audit` como internos; opcional `api` exclusivamente para objetos explicitamente expostos. Revisar GRANT, exposição da Data API e RLS; schema por si só não garante isolamento.

- **Operação inicial:** uma máquina de workers com processamento por lotes e agendamento simples. Escala horizontal somente após medição.

3.5 Sequência do job de scraping

1. O operador autorizado solicita **Iniciar coleta** no painel (modo manual) **ou** o processo agendador consulta regras ativas e identifica agendas vencidas (modo automático).
2. No modo manual a API valida o usuário; no modo automático o scheduler autentica como serviço restrito. Ambos validam fonte, domínio, janela, orçamento, permissões e escopo da requisição.
3. O serviço grava job `pendente` com chave de idempotência e origem de acionamento (`manual` ou `automatico`), preservando solicitante ou agenda responsável.
4. Um worker reserva o job atomicamente, registra lease e heartbeat e muda para `executando`.
5. O spider carrega apenas páginas autorizadas; usa Playwright somente se necessário.
6. O pipeline salva observações e referências de evidência em transações curtas.
7. A consolidação valida, calcula qualidade e atualiza contatos sem alterar `lead_comercial`.
8. O worker finaliza métricas, checkpoint e estado. Em falha, registra motivo, política de retentativa e alerta.
9. A API apresenta histórico, contagem de registros e eventuais necessidades de revisão.

3.6 Máquina de estados dos jobs

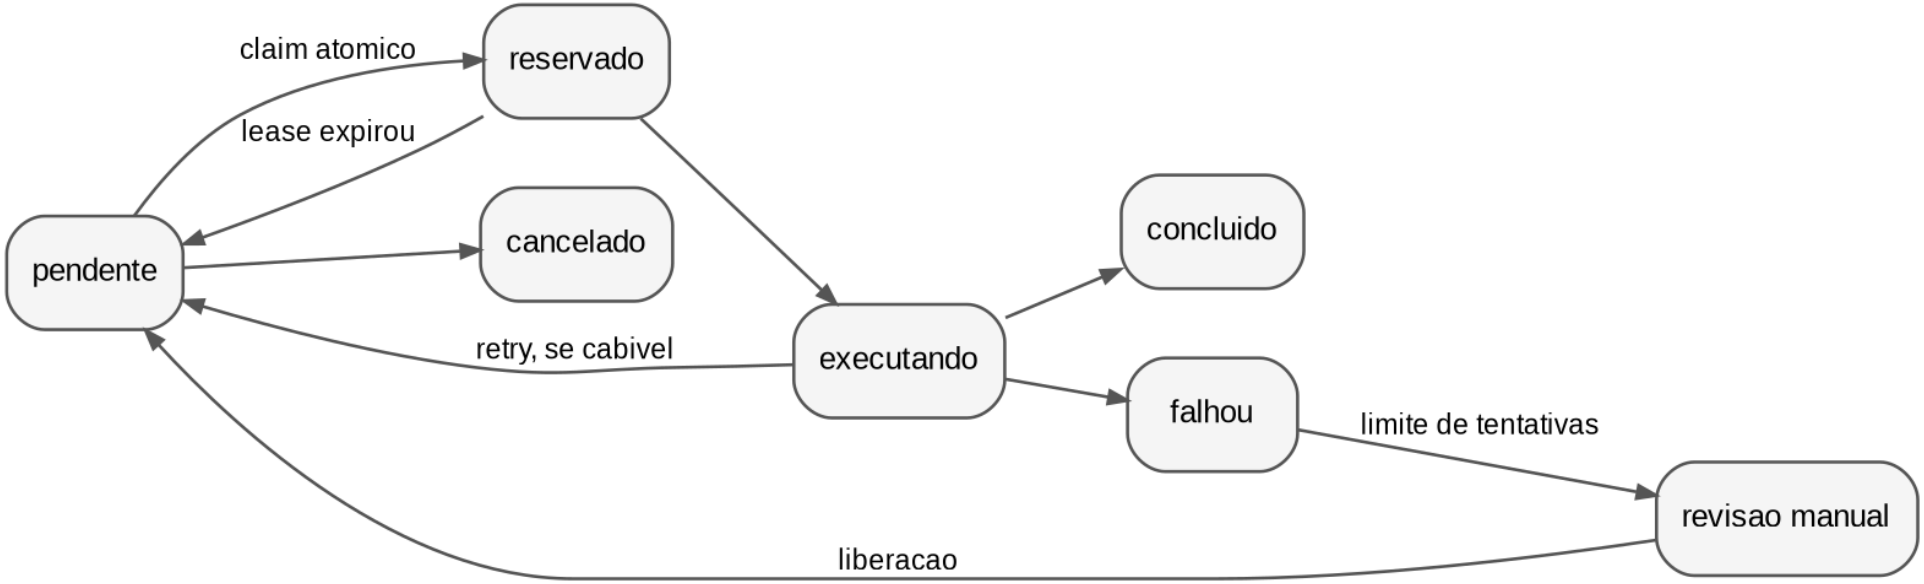


Figura 3 - Estados sugeridos para execução de jobs

Regras de execução: `claim` via transação com `FOR UPDATE SKIP LOCKED`, lease por worker, heartbeat periódico e reatribuição de lease expirado. A reexecução é idempotente. O mecanismo de retry deve distinguir falhas transitórias, permanentes e bloqueios por política. Jobs encerrados após tentativas máximas vão para revisão em vez de loop infinito. A origem manual ou automática **não** modifica as regras técnicas do coletor.

3.7 Acionamento manual e automático das coletas

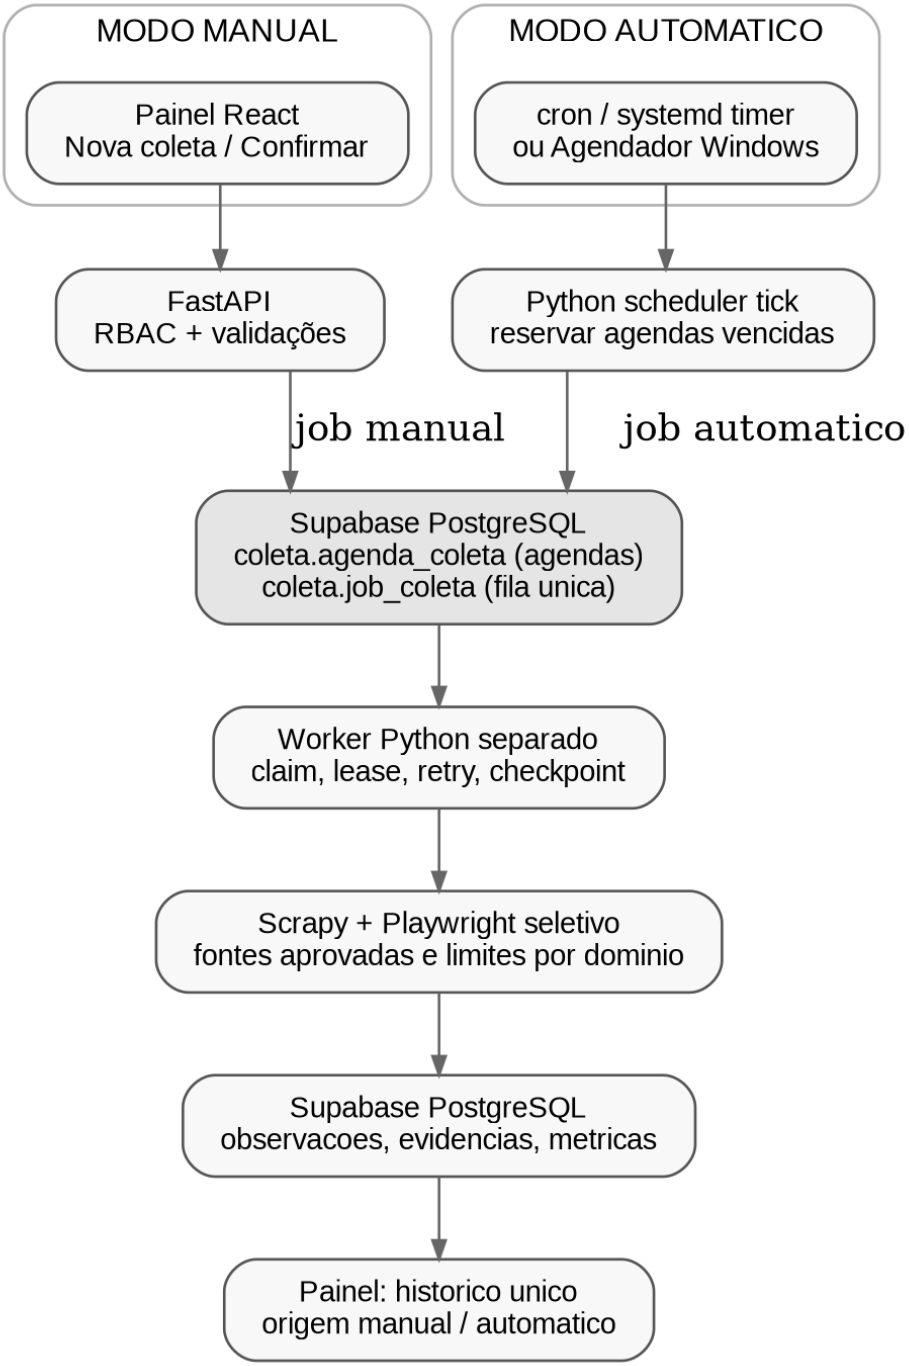


Figura 4 - Acionamento manual e automático convergindo para a mesma fila de jobs

Decisão de arquitetura: a plataforma terá **dois meios de solicitar uma coleta**, mas **um único fluxo de execução**. Isso evita manter dois scrapers diferentes, impede divergências de validação e facilita testes e auditoria.

Dimensão	Modo manual	Modo automático
Quem dispara	Operador/admin autenticado no dashboard	Processo agendador Python autorizado, iniciado pelo SO
Configuração	Fonte, UF/município ou domínio, escopo e confirmação	Regra ativa com fonte, partição, periodicidade, horário e fuso
Primeira ação	`POST /v1/jobs` pela FastAPI	Comando `scheduler tick` consulta agendas vencidas no Supabase
Persistência	Insere `coleta.job_coleta` com `origem=manual` e `solicitado_por`	Insere `coleta.job_coleta` com `origem=automatico` e `agenda_id`
Execução real	Worker Python reserva e processa o job em segundo processo	Mesmo worker Python e mesmos spiders
Feedback	Tela de monitor exibe ID, status, progresso e erros	Tela mostra agenda, próxima execução, última execução e jobs gerados
Interrupção	Operador pode solicitar cancelamento de job permitido	Admin pode pausar agenda e cancelar jobs ainda pendentes, conforme política

Fluxo manual (P0): (1) operador abre **Coletas > Nova coleta**; (2) seleciona fonte autorizada, região/domínio, tipo de coleta e escopo; (3) interface apresenta uma prévia dos parâmetros e exige confirmação; (4) FastAPI aplica RBAC e valida limites, política por fonte e duplicidade ativa; (5) job entra como `pendente`; (6) o worker executa; (7) o operador acompanha o resultado por ID no monitor. A resposta HTTP deve retornar **202 Accepted** com `job_id`, sem esperar o navegador terminar o crawl. Clicar repetidamente não deve duplicar trabalho equivalente em andamento.

Fluxo automático (P0): (1) admin cadastra e habilita uma agenda; (2) o `cron`, `systemd timer` ou Agendador do Windows inicia periodicamente um **comando Python curto**, por exemplo uma vez por minuto; (3) esse comando lê no PostgreSQL/Supabase agendas com `proxima_execucao_em <= agora`, reserva cada agenda atomicamente, verifica limites e cria o job; (4) avança `proxima_execucao_em` na mesma transação, para evitar novo disparo; (5) o worker independente processa a fila. **O Supabase armazena agendas e jobs; o agendador e o navegador automatizado rodam fora dele.**

Periodicidades propostas: diária, semanal ou mensal, com horário local e timezone IANA configurado (ex.: `America/Sao_Paulo`). Expressões cron livres não serão inseridas diretamente pelo usuário no MVP; a interface oferece opções validadas. A rotina mensal da Receita e a revalidação periódica de contatos podem usar o mesmo mecanismo, com tipos de job distintos. A agenda não representa promessa de execução quando a máquina estiver desligada.

Política para atrasos e indisponibilidade: quando o computador/servidor estiver desligado na hora prevista, não haverá execução naquele instante. No retorno, cada agenda poderá executar **no máximo um disparo de recuperação** ou ignorar a janela vencida, conforme `politica_atraso`, nunca criar uma avalanche de jobs retroativos. Horário de verão e mudanças de fuso devem ser tratados por biblioteca de timezone, armazenando instantes no banco em UTC.

Concorrência e prevenção de duplicidade: criar uma chave de idempotência calculada a partir de fonte, partição, tipo de coleta e janela lógica; impedir sobreposição simultânea da mesma tarefa; reservar agendas e jobs em transações PostgreSQL com locks adequados. Conflitos devolvem o job existente ou informam que já há execução ativa. Falha no envio de comando não pode gerar dois jobs equivalentes.

Governança e proteção: apenas operador/admin inicia manualmente; somente admin configura, suspende ou edita agendas; comercial tem acesso no máximo à visualização permitida. Registrar usuário, agenda, origem, timestamp, filtros, motivo da recusa e mudanças de configuração. Política de domínio, limites de taxa, retenção, supressão e orçamento valem igualmente para ambos os modos.

Critério de homologação obrigatório: demonstrar uma coleta disparada pelo botão do painel e outra disparada automaticamente pelo agendador do SO, ambas visíveis no mesmo histórico, sem duplicação, com capacidade de falhar e retomar sem alterar dados comerciais.

4. Levantamento de requisitos funcionais

4.1 Convenções

`P0` = indispensável para o MVP; `P1` = necessário antes de operação regular; `P2` = evolução. Os critérios listados são verificáveis. Todos os requisitos são **propostas de produto a aprovar**, salvo as decisões fixadas no resumo de escopo.

4.2 Catálogo de requisitos funcionais

ID	Pri.	Requisito verificável	Critério de aceite resumido
RF-001	P0	Cadastrar fontes com tipo, permissão, risco, URL de termos e status	Fonte sem aprovação não é executada
RF-002	P0	Parametrizar CNAE principal, situação ativa e recorte por UF/município	Recorte reproduzível para a mesma versão

ID	Pri.	Requisito verificável	Critério de aceite resumido
RF-003	P0	Registrar competência, origem, integridade e layout de cada carga CNPJ	Carga sem verificação fica bloqueada
RF-004	P0	Importar estabelecimentos elegíveis para staging e base mestre	Reconciliação por UF e relatório de rejeição
RF-005	P0	Preservar snapshot/versão cadastral e data de última observação	Possível identificar inclusões e alterações
RF-006	P0	Deduplicar por CNPJ completo e manter filiais separadas	CNPJ repetido não duplica estabelecimento
RF-007	P0	Criar e gerenciar jobs por fonte/UF/município/domínio	Estados e tentativas consultáveis
RF-008	P0	Retomar jobs interrompidos com checkpoint/lease	Retomada não duplica contatos/evidências sem critério
RF-009	P0	Descobrir URLs candidatas a site institucional	Cada URL tem origem e situação de revisão
RF-010	P0	Associar site ao CNPJ por evidências objetivas	Casos ambíguos não viram associação automática
RF-011	P0	Executar crawling com respeito a políticas por domínio	Testes provam limite, pausa e bloqueio
RF-012	P0	Usar browser somente em páginas dinâmicas autorizadas	Caminho HTTP simples não inicia browser
RF-013	P0	Extrair telefone, e-mail, links de WhatsApp, site e perfis publicados	Valores brutos e URL da observação registrados
RF-014	P0	Criar evidência de cada observação extraída	Fonte, URL, horário e hash rastreáveis
RF-015	P0	Normalizar CNPJ, CEP, domínio, telefone e e-mail	Formatos inválidos são classificados/rejeitados
RF-016	P0	Identificar telefones/e-mails potencialmente compartilhados	Central e contabilidade recebem marca própria

ID	Pri.	Requisito verificável	Critério de aceite resumido
RF-017	P0	Consolidar observações sem apagar origem ou histórico	Contato final aponta para observações utilizadas
RF-018	P0	Diferenciar validade técnica, confirmação de vínculo e autorização de uso	Interface não exibe apenas rótulo genérico “validado”
RF-019	P0	Preservar campos comerciais em toda atualização de scraping	Reimportação não altera status, dono e notas
RF-020	P0	Autenticar usuários e impor permissões por papel	Usuário não autorizado recebe 403 ou ausência do recurso
RF-021	P0	Listar estabelecimentos por UF, município, CNAE, situação e contato	Busca paginada com filtros consistentes
RF-022	P0	Exibir ficha de estabelecimento com fontes e datas de contato	Contato mostra procedência e tipo de confiança
RF-023	P0	Criar/alterar status comercial e responsável	Histórico registra usuário, antes/depois e data
RF-024	P0	Registrar observações e interações comerciais manuais	Nenhuma observação desaparece após nova coleta
RF-025	P0	Manter lista de supressão por contato/canal	Exportação exclui contatos suprimidos
RF-026	P0	Exportar somente contatos permitidos por papel e política de canal	Exportação gera trilha auditável
RF-027	P0	Registrar auditoria de login relevante, atualização e exportação	É possível responder quem fez o quê e quando
RF-028	P0	Consultar resultado de jobs: aceitos, erros, duração, motivo e cobertura	Tela e API mostram estado real da execução
RF-029	P1	Colocar domínio/fonte em pausa após sequência de falhas ou bloqueios	Pausa evita tentativas repetitivas
RF-030	P1	Reprocessar fontes em janela configurável com idempotência	Nova coleta não cria o mesmo lead novamente

ID	Pri.	Requisito verificável	Critério de aceite resumido
RF-031	P1	Oferecer fila de revisão humana de vínculos ambíguos	Revisão aprovada/rejeitada gera trilha
RF-032	P1	Calcular score de confiança explicável por contato	Score inclui sinais, penalidades e versão de regra
RF-033	P1	Medir cobertura, precisão amostral, erros e frescor por UF	Dashboard não confunde percentual de sites com de contatos
RF-034	P1	Atualizar a base mestre após nova carga oficial	Relatório de estabelecimentos novos, alterados e inativos
RF-035	P1	Classificar domínios com falha de SSRF/redirecionamento	URL interna ou privada é recusada
RF-036	P1	Gerar pedidos de correção, bloqueio e exclusão conforme política	Solicitação recebe estado, responsável e prazo
RF-037	P1	Manter política de retenção e limpeza de HTML/evidências	Purga periódica registra resultado
RF-038	P1	Gerenciar orçamento e limites de APIs pagas por fonte	Bloqueia chamadas após teto definido
RF-039	P2	Integrar CRM externo por API após aprovação	Sincronização não duplica e respeita supressão
RF-040	P2	Suportar mapa/consulta por raio se houver demanda	Exige revisão de licença de geocodificação
RF-041	P2	Oferecer perfis/grupos empresariais sem mesclar filiais	Grupo reúne múltiplos CNPJs distintos
RF-042	P2	Analisar feedback do comercial sobre contatos incorretos	Feedback influencia recrawl ou revisão de score
RF-043	P2	Importar cadastros complementares oficiais com proveniência	Fonte nova não sobrescreve dado sem regra
RF-044	P2	Gerar relatórios de qualidade por fonte e versão do spider	Queda de extração é detectável por release

ID	Pri.	Requisito verificável	Critério de aceite resumido
RF-045	P0	Iniciar coleta manual a partir do dashboard, com fonte e região/domínio	API retorna 202 e ID de job; status visível sem bloquear interface
RF-046	P0	Validar permissão, parâmetros, limites e execução concorrente no disparo manual	Clique duplicado não cria job equivalente ativo; usuários sem papel recebem 403
RF-047	P0	Cadastrar, ativar, pausar e editar agendas recorrentes	Admin configura periodicidade, horário, timezone, fonte e escopo; histórico auditado
RF-048	P0	Criar automaticamente jobs vencidos por comando Python acionado pelo agendador do SO	Execução da agenda gera job `automatico`, mesmo pipeline e métricas do manual
RF-049	P0	Impedir duplicidade em disparos simultâneos ou após reinício do agendador	Duas chamadas do scheduler para a mesma janela produzem no máximo um job lógico
RF-050	P0	Exibir origem, solicitante/agenda, próxima e última execução no painel	Operador distingue manual/automático e identifica falhas e atrasos
RF-051	P1	Definir política para janelas perdidas por máquina desligada	Na retomada, no máximo um catch-up por agenda ou pular janela, conforme configuração
RF-052	P1	Permitir cancelamento controlado e suspensão de novas coletas	Cancelamento de job pendente é imediato; em execução é cooperativo, auditado
RF-053	P1 condicionado	Pesquisar farmácias via Google Places Text Search e Nearby Search	Filtros de termo, categoria, região e raio; mostrar resultados/`place_id` e atribuição após aprovações contratuais
RF-054	P1 condicionado	Consultar Place Details de farmácia selecionada	Exibir telefone/site quando disponíveis em resposta atual; não persistir conteúdo restrito automaticamente
RF-055	P1 condicionado	Relacionar `place_id` a CNPJ/estabelecimento existente com revisão de ambiguidade	Persistir somente o identificador permitido; correspondência sem garantia não atualiza contatos nem razão social

ID	Pri.	Requisito verificável	Critério de aceite resumido
RF-056	P1 condicionado	Controlar consumo e custos das consultas Google	FieldMask mínimo, SKUs, limites por usuário/organização, erros e teto diário/mensal monitorados
RF-057	P1 condicionado	Impedir exportação ou ingestão no Supabase de conteúdo restrito recebido exclusivamente da Places API	Testes de negativa de gravação, atribuições e segregação por origem
RF-058	P2 opcional	Avaliar Places Insights para descoberta territorial em escala nacional	Acesso contratado ao BigQuery, disponibilidade Brasil, custos e limites de resultados documentados antes do projeto

RF-059 | P0 | Manter um catálogo de **múltiplas fontes** com finalidade, contrato/licença, classe de dados, periodicidade, escopo e responsável | Fonte `pendente`/`bloqueada` não pode gerar observação publicável nem executar job |
RF-060 | P0 | Definir regras de uso por `fonte + campo + operação` (coletar, persistir, exibir, exportar) | Telefone com persistência negada não aparece em `core.contato` ou CSV |
RF-061 | P0 | Integrar lista oficial Farmácia Popular como fonte complementar após inspecionar campos e direitos de uso | Importação identifica versão e cruza CNPJ sem sobrescrever dados comerciais |
RF-062 | P1 | Integrar consultas públicas da Anvisa para qualificação cadastral, conforme mecanismo autorizado | Consulta sem API/bulk permitidos fica em modo manual e não gera scraping não autorizado |
RF-063 | P0 | Registrar contato fornecido diretamente pelo estabelecimento ou autorizado pelo comercial | Registrar autor, evidência de origem, finalidade, data e classificação do canal |
RF-064 | P1 | Importar fornecedores B2B licenciados e arquivos CSV homologados | Contrato e campos autorizados registrados; ausência de contrato bloqueia publicação |
RF-065 | P1 | Importar extratos OpenStreetMap, condicionado a avaliação ODbL e separação de dataset | Atribuição/licença preservadas e exportação verificada segundo obrigação aplicável |
RF-066 | P0 | Consolidar múltiplas observações por CNPJ sem apagar versões, conflitos ou proveniência | Mesmo telefone de duas fontes produz um contato e duas evidências distintas |
RF-067 | P0 | Bloquear enriquecimento derivado de conteúdo Google Places sem autorização específica | Nenhuma rotina importa resposta Places ou usa a busca Google como origem oculta do scraper |
RF-068 | P1 | Mostrar cobertura, custo, frescor, rejeições e desempenho **por fonte** e por UF | Dashboard exibe denominador, competência e período da medição |
RF-069 | P1 | Permitir importar/pausar/reprocessar individualmente conectores por fonte, UF

ou domínio | Pausa de uma fonte não interrompe as demais |
RF-070 | P0 | Aplicar autorização de exportação por contato/canal e procedência | Um contato suprimido, restrito, pessoal sem revisão ou de licença incompatível não sai no arquivo |
RF-071 | P1 | Registrar e revisar conflitos de fontes (telefones diferentes, CNPJ ambíguo, endereços divergentes) | Divergência sem regra confiável entra em fila de revisão, sem substituir automaticamente o consolidado |
RF-072 | P1 | Permitir análise de valor por fonte para priorizar orçamento | Relatório de novos CNPJs, contatos únicos elegíveis e custo por contato válido, sem inflar duplicações |

4.3 Casos de uso essenciais

UC-01 - Importar base oficial. Ator: operador de dados. Pré-condições: fonte aprovada e espaço disponível. Fluxo: registrar versão -> baixar -> verificar checksum/layout -> filtrar CNAE principal -> staging -> reconciliar -> promover -> emitir relatório. Exceções: corrupção, layout diferente, contagens fora do intervalo; não promover.

UC-02 - Descobrir e confirmar site. Ator: serviço de descoberta e revisor. Fluxo: identificar domínio candidato -> guardar evidência -> comparar identificadores/telefone/endereço -> confirmar se houver critério forte; se ambíguo, enviar à revisão humana.

UC-03 - Executar enriquecimento por scraping. Ator: agendador/operador. Pré-condições: fonte permitida, domínio aceito e job válido. Fluxo: reservar job -> rastrear páginas de contato -> extrair -> validar -> persistir observações -> consolidar -> atualizar métricas. Exceções: 429, 5xx, `robots.txt`, bloqueio explícito, dados inconsistentes, redirecionamento inseguro.

UC-07 - Disparar coleta manualmente. Ator: operador ou administrador. Pré-condições: sessão autenticada, fonte aprovada e parâmetros válidos. Fluxo: abrir tela de coletas -> informar região/domínio e fonte -> confirmar -> solicitar API -> receber `job_id`/202 -> acompanhar progresso. Exceções: 403, fonte bloqueada, orçamento excedido, job duplicado em andamento ou ausência de worker; registrar o resultado e informar na interface.

UC-08 - Executar coleta agendada. Ator: agendador do sistema operacional e serviço Python. Pré-condições: agenda ativa, horário vencido, máquina ligada e credencial de serviço válida. Fluxo: iniciar `scheduler tick` -> reservar agenda -> criar job idempotente -> atualizar próxima ocorrência -> worker coleta -> registrar resultado. Exceções: tick duplicado, banco indisponível, horário perdido e agenda pausada; não criar múltiplos jobs para a mesma janela.

UC-04 - Qualificar lead comercial. Ator: vendedor. Fluxo: consultar lista -> abrir ficha -> observar origem/qualidade -> designar responsável -> alterar status e registrar comentário. A ação é auditada.

UC-05 - Exportar contatos. Ator: perfil autorizado. Fluxo: filtrar -> aplicar supressão, elegibilidade por canal e regras de permissão -> gerar arquivo temporário -> registrar quantidade e solicitante -> permitir download seguro. Em caso de restrição, informar causa sem expor dados indevidos.

UC-06 - Tratar opt-out. Ator: responsável autorizado. Fluxo: receber solicitação -> localizar canal/contato -> aplicar supressão -> propagar a integrações pertinentes -> manter registro mínimo necessário para impedir novas abordagens.

5. Requisitos não funcionais

ID	Eixo	Requisito e verificação	Meta sugerida para aceite
RNF-001	Segurança	TLS em todos os acessos externos	Obrigatório
RNF-002	Segurança	Senhas e tokens não ficam no frontend, repositório ou logs	0 ocorrências em análise de segredos
RNF-003	Segurança	Princípio de privilégio mínimo em Supabase e API	Testes negativos de todas as funções P0
RNF-004	Segurança	RLS nos objetos expostos pela Data API; restrição por GRANT/schema	Política testada em homologação
RNF-005	Segurança	Validação de URL contra SSRF, IPs privados, redirecionamentos	100% dos casos automatizados de bloqueio
RNF-006	Segurança	Limitar upload/download e sanitizar texto antes de exibir	Testes contra XSS e arquivo malicioso
RNF-007	Privacidade	Origem, finalidade, retenção e elegibilidade por canal rastreáveis	Nenhum contato exportado sem regra
RNF-008	Privacidade	Evidências/HTML não são públicos e expiram por política	Testar acesso não autenticado e purga
RNF-009	Privacidade	Supressão prevalece sobre segmentação/exportação	Zero casos de vazamento em testes
RNF-010	Integridade	`cnpj` único, FKs e constraints em registros essenciais	Inserção duplicada não corrompe dados
RNF-011	Integridade	Atualização idempotente e transacional por lote	Rodar lote 2 vezes sem duplicar

ID	Eixo	Requisito e verificação	Meta sugerida para aceite
RNF-012	Integridade	Reprocessamento não altera status nem notas comerciais	Zero divergências em teste de regressão
RNF-013	Disponibilidade	Interface e API têm monitoramento e healthcheck	Disponibilidade alvo a pactuar após piloto
RNF-014	Desempenho	Consultas paginadas com índices apropriados	p95 <=2 s para 50 itens no cenário de referência
RNF-015	Desempenho	Coleta obedece a limite por domínio e recuo em 429/5xx	Evidência em testes com servidor simulado
RNF-016	Escalabilidade	Crescimento por workers independentes sem partilhar browser entre jobs	Testes de concorrência com isolamento
RNF-017	Escalabilidade	Não carregar toda a Receita por inserts HTTP individuais	Importação em lote ou `COPY`
RNF-018	Resiliência	Lease e recuperação de jobs abandonados	Job retomado após encerramento forçado
RNF-019	Resiliência	Retry limitado e tratamento distinto de falha permanente	Nenhum loop de tentativas sem fim
RNF-020	Observabilidade	Logs estruturados com job_id, fonte_id, versão e causa	100% dos jobs críticos rastreáveis
RNF-021	Observabilidade	Alertar sobre queda de volume, erro e campos que sumiram	Alerta em teste de degradação
RNF-022	Qualidade	Testes unitários, integração, contrato, E2E e RLS	Todos os testes P0 aprovados
RNF-023	Qualidade	Linters, typing e migrations em CI	Pipeline bloqueia merge com erro
RNF-024	Recuperação	Backup e restauração do PostgreSQL efetivamente testados	RPO/RTO a aprovar; proposta 24h/8h
RNF-025	Recuperação	Evidências do Storage têm estratégia separada de backup	Teste de recuperação de objeto e metadado
RNF-026	Manutenibilidade	Componentes de coleta independem da API e UI	Teste CLI funciona sem API online
RNF-027	Manutenibilidade	Mudanças de esquema sempre versionadas	Alembic e revisão SQL obrigatórios

ID	Eixo	Requisito e verificação	Meta sugerida para aceite
RNF-028	Auditabilidade	Exportação, alteração comercial e supressão têm log imutável no nível de aplicação	Registros com ator, momento e ação
RNF-029	Portabilidade	Processos executáveis em ambiente virtual Python, com configuração externa e scripts de inicialização	Rodar desenvolvimento e homologação sem alterar o código e sem contêineres
RNF-030	Custos	Monitorar armazenamento, egress, conexões, jobs, browser e APIs	Limites e alertas configurados antes de produção
RNF-031	Agendamento	A mesma lógica de validação, concorrência e spider é usada por coletas manuais e automáticas	Teste de paridade de resultados e políticas
RNF-032	Agendamento	Disparos simultâneos e reinícios não criam jobs duplicados na mesma janela	100% dos cenários automatizados sem duplicidade lógica
RNF-033	Operação	O agendamento não depende de um navegador aberto, mas requer worker e máquina ativos	Teste com painel fechado; indisponibilidade visível no monitor
RNF-034	Auditoria	Toda coleta registra origem, solicitação, horário, parâmetros e resultado	Job rastreável por ID e, quando aplicável, por agenda e usuário
RNF-035	Integração Google	Chave/API restrita ao backend, segregada por ambiente, com quota e alertas de faturamento	Testes de vazamento de segredo, negação por quota e orçamento
RNF-036	Integrações Google	Conteúdo Places segue controles de retenção, atribuição e finalidade contratados	Testes impedem INSERT/exportação de campos cuja retenção não foi autorizada
RNF-037	Custos externos	Registrar consumo por API, impor tetos e monitorar erros de quota	Teste de orçamento esgotado e pausa segura

Nota: tempos e percentuais são metas propostas, não compromissos de capacidade já demonstrada. O cenário de medição deve fixar quantidade de estabelecimentos, concorrência, filtros, volume de dados, compute e plano do Supabase.

6. Regras de negócio e decisão de qualidade

ID	Regra	Justificativa
RN-001	Um CNPJ completo corresponde a um estabelecimento mestre	Não fundir matriz e filial
RN-002	CNAE secundário é candidato para revisão, não entrada automática no universo	Evitar falso positivo no recorte
RN-003	Só promover lotes oficiais com layout reconhecido e conferência quantitativa	Evitar corrupção silenciosa
RN-004	Um site candidato não é site confirmado	Vínculo equivocado é risco comercial
RN-005	Domínios bloqueados ou proibidos não serão rastreados	Respeitar permissões e restrições
RN-006	Evidência observada é imutável; consolidação pode ser recalculada	Auditoria e reprocessamento
RN-007	Score é explicável e versionado; limiares exigem calibração	Evitar percentuais arbitrários
RN-008	Contato pode estar tecnicamente válido sem pertencer ao estabelecimento	Precisão do lead
RN-009	Um link de WhatsApp publicado não significa opt-in para campanhas	Condição de abordagem distinta de descoberta
RN-010	E-mail de contabilidade e central de rede deve ter classificação específica	Evitar contato comercial incorreto
RN-011	Coleta nunca escreve em tabela de gestão comercial	Preservar trabalho do vendedor
RN-012	Supressão tem precedência em exportação e integração de envio	Respeitar oposição/opt-out
RN-013	Acesso a dados e exportações depende de perfil de usuário	Minimização de acesso
RN-014	Todos os horários persistidos em UTC, exibidos conforme fuso de interface	Auditoria coerente
RN-015	URL externa passa por validação de esquema, DNS, IP e redirecionamento	Prevenção de SSRF
RN-016	Só fontes com permissão e finalidade documentadas entram na execução	Governança operacional

ID	Regra	Justificativa
RN-017	Disparo manual e automático entram na mesma fila e obedecem à mesma política	Evitar dois motores de coleta inconsistentes
RN-018	Uma agenda pausada não gera novos jobs; pausa não significa cancelar automaticamente job já em execução	Previsibilidade operacional
RN-019	A mesma partição/fonte/janela não deve originar coletas concorrentes equivalentes	Controle de recursos e deduplicação
RN-020	Admin controla agendas; operador cria jobs manuais; comercial não dispara coletas	Restrição de acesso por papel
RN-021	O requisito de descoberta de farmácias no Google Maps utiliza Places API (New), não Google Business Profile API	Google Business Profile é para locais próprios ou autorizados
RN-022	Dados da Places API não são promovidos automaticamente a `core.estabelecimento`, `core.contato` ou `coleta.observacao_coleta`	Cumprir termos de cache, armazenamento e finalidade; exceções específicas exigem avaliação
RN-023	`place_id` é referência externa; associação a CNPJ deve ser validada e não substitui cadastro oficial	Evitar confundir local Google com identidade fiscal
RN-024	Google Places nunca será acessado por scraping do site Maps nem usado para alimentar automaticamente contatos persistentes no Supabase	Separar consulta contextual de ingestão autorizada

6.1 Estados de qualidade de um contato

Um contato terá dimensões independentes: `validade_formato` (válido, inválido, indeterminado), `vinculo_estabelecimento` (confirmado, provável, não confirmado, rejeitado), `atualidade` (recente, vencida, desconhecida) e `uso_canal` (permitido sob política, restrito, suprimido). O score numérico poderá apoiar priorização, mas nunca substitui essas dimensões nem decide sozinho sobre licitude do tratamento.

6.2 Deduplicação

- Chave forte: CNPJ completo validado; persistência com UNIQUE.
- Raiz de CNPJ: agrupamento empresarial, sem fusão de unidades.
- Fonte sem CNPJ: sugestão de associação por nome, endereço e telefone, com limiares calibrados em amostra rotulada.

- Contato compartilhado: registrar associação a várias unidades, mas sinalizar central, rede ou contador.
- `UPSERT` de contato: chave natural composta por estabelecimento, tipo e valor canônico; evidências devem apontar para observações distintas sem reproduzir o mesmo evento em reexecuções.

7. Especificação de coleta e web scraping

7.1 Catálogo inicial de fontes

Fonte	Papel	Coleta inicial	Condição de uso
Receita Federal - dados abertos de CNPJ	Universo cadastral e contatos de cadastro	Download e processamento de arquivos	Validar versão oficial e tratamentos de eventuais dados pessoais
Sites oficiais das farmácias	Complemento de e-mail, telefone, WhatsApp e site	Scrapy; Playwright quando necessário	Respeitar termos, políticas, limites e finalidade
Localizadores de redes	Contato/endereço por unidade	Spider especializado por domínio	Autorizar e verificar regras individualmente
Listas públicas de órgãos de saúde	Indícios de credenciamento/regularidade	Download/API caso disponível	Validar identidade e condições de reutilização
Google Places API (Google Maps Platform)	Descoberta e consulta de farmácias de terceiros no Google Maps	Text Search, Nearby Search e Place Details (API oficial); armazenar `place_id`	Resultados/contatos sob restrições de cache e atribuição; não exportar campos restritos como base de leads
Google Places Insights (evolução)	Inteligência territorial e IDs de locais no Brasil	BigQuery/assinatura do produto, se viável	Contratação e custos separados; validar cobertura e limites da consulta
Instagram Business Discovery	Metadados limitados, se houver caso aprovado	API oficial	Não raspar Instagram nem presumir acesso a contato privado

7.2 Desenho dos spiders

Spider / módulo	Entrada	Saída	Critério de fallback
`institutional_site_spider`	Site confirmado	Páginas de contato/sobre/rodapé e links	HTTP simples primeiro
`chain_locator_spider`	Fonte de rede autorizada	Unidade, telefone, endereço e evidência	Parser específico com testes de contrato
`dynamic_contact_spider`	URL dinâmica autorizada	DOM renderizado e contatos	Playwright se sem dados em HTML estático

Spider / módulo	Entrada	Saída	Critério de fallback
`candidate_discovery`	CNPJ, cidade e sinais oficiais	Domínios candidatos e proveniência	Revisão humana quando vínculo fraco
`official_data_ingestor`	Arquivos oficiais e metadados	Lotes filtrados, snapshot e relatório	Não é spider web; pipeline separado
`google_places_search` (condicional)	Região/cidade/termo ou área/raio	Lista de `place_id` e resultados transitórios com atribuição	API oficial, não spider; limite de resultados não equivale a cobertura total
`google_places_details` (condicional)	`place_id` selecionado pelo usuário	Dados de contato atuais apenas para exibição permitida	Não promover conteúdo restrito ao pipeline comercial persistido

7.3 Política técnica de rastreamento

1. Scrapy com `ROBOTSTXT_OBEY`, identificador de agente e canal de contato do operador.
2. Concorrência por domínio explicitamente limitada; AutoThrottle e atraso configuráveis.
3. Retentativas restritas a falhas transitórias, com backoff e `Retry-After`; bloqueios explícitos interrompem coleta.
4. Allowlist de domínios por fonte; limite de profundidade e páginas por estabelecimento; sem login, CAPTCHA bypass ou rotação para evasão.
5. Download timeout, tamanho máximo de resposta e controles de memória por worker/browser.
6. Proibição de URL localhost, metadata endpoints, IP privado, DNS rebinding e redirecionamentos internos.
7. Não renderizar/armazenar HTML bruto indefinidamente; evidência mínima necessária, com retenção definida.
8. A estratégia de checkpoint do Scrapy pode usar `JOBDIR` por execução; esta pasta é local ao job e não compartilhada entre spiders. Estado macro permanece em `job_coleta`.

7.4 Contrato de observação de campo

Cada valor extraído será registrado com `estabelecimento_candidato_id`, `campo`, `valor_bruto`, `valor_normalizado`, `fonte_id`, `job_id`, `url`, `trecho_limitado`, `hash_conteudo`, `coletado_em`, `versao_spider` e `status_validacao`. Um campo pode ser apenas uma *observação* e não deve aparecer como contato confirmado até que o resolvedor aprove a associação.

7.5 Tratamento de erros

Situação	Ação obrigatória
HTTP 429	Respeitar `Retry-After`; reduzir taxa; limitar retries
HTTP 500/502/503	Backoff com máximo de tentativas; registrar causa
HTTP 403 / bloqueio	Parar domínio/job e enviar à revisão; não contornar
Layout alterado	Quarentena do parser, alerta por campos ausentes e fixture nova
Site indisponível	Preservar última evidência, reduzir atualidade e planejar revalidação
CNPJ inválido	Rejeitar vínculo automático; registrar erro de origem
Timeout JavaScript	Encerrar contexto do browser, liberar recurso e finalizar com status rastreável
Supabase indisponível	Buffer limitado e retry idempotente; não perder checkpoint silenciosamente

7.6 Google Maps: descoberta de farmácias e consulta de contatos (escopo confirmado)

Necessidade confirmada pelo negócio: procurar farmácias no Google Maps e visualizar os contatos comerciais que constem das fichas. A solução correta é **Google Places API (New)**, não Google Business Profile. Esta última exige acesso aos perfis próprios/autorizados e não será desenvolvida para a prospecção de terceiros.

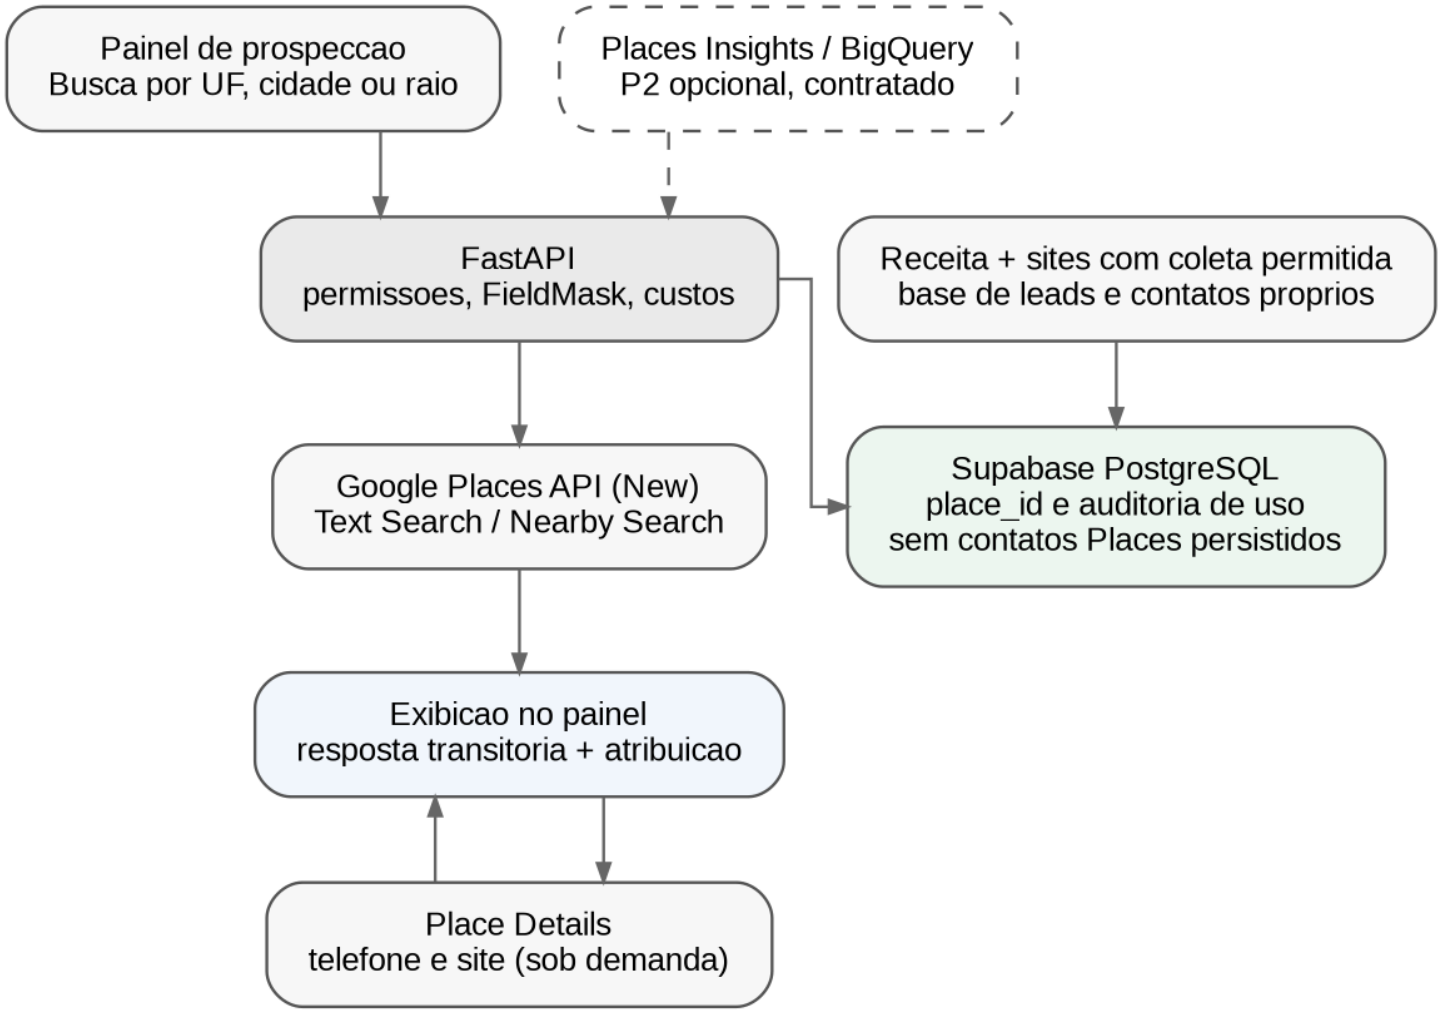


Figura 5 - Descoberta no Google Maps sem ingestão de conteúdo restrito

Fluxo de busca proposto: (1) operador escolhe UF, município, termo ou área no painel; (2) FastAPI valida papel, parâmetros e orçamento; (3) usa Text Search para consultas por texto e/ou Nearby Search com área e categoria; (4) os resultados são apresentados com atribuição e, quando elegível, o `place_id` pode ser salvo como referência; (5) operador seleciona a farmácia e, sob demanda, chama Place Details para contato/site; (6) a interface exibe esses dados de forma transitória, sem gravar telefone, endereço, nome ou site recebidos exclusivamente da Places no CRM; (7) o sistema pode solicitar revisão de correspondência com um CNPJ mestre usando dados que possua legitimamente por outras fontes. **Não** presumir que toda busca retorna todas as farmácias: Text Search limita resultados e relevância, e Nearby Search depende da área e parâmetros.

Componente Google	Uso projetado	Dados no Supabase	Limitação relevante
Text Search (New)	Pesquisar “farmácias em [município]” ou termos associados	ID do lugar, parâmetros e métricas próprias da consulta, sem copiar campos restritos	Máximo documentado de 60 resultados no total por consulta paginada; resultado não é universo completo
Nearby Search (New)	Procurar tipo de local por raio geográfico	`place_id` e auditoria de custo/uso, sob regras aplicáveis	Requer área/raio; resultados são recorte, não cobertura nacional garantida
Place Details (New)	Exibir telefone comercial, site e dados da ficha escolhida	Somente `place_id` como referência persistente por padrão	Telefone/site são campos de cobrança mais elevada; não podem ser armazenados livremente
Places Insights (P2 opcional)	Prospectar áreas e identificar IDs de locais por BigQuery	IDs permitidos vinculados ao CRM próprio	Produto por assinatura, acessível mediante contratação e com limites de consulta
Scrapy + Playwright	Extrair contatos de **sites independentes** com crawling autorizado	Evidências, contatos e proveniência dessas fontes, se licenças permitirem	Não utilizá-lo no site Google Maps nem como rota para contornar restrições da Places API

Esquema recomendado: `core.google_place_ref(estabelecimento_id, place_id, vinculado_em, metodo_vinculo, revisado_por)` com referência única por local e `audit.google_places_consulta(id, usuario_id, endpoint, campo_mask, sku_prevista, custo_estimado, status, criado_em)`. Esta última tabela guarda metadados operacionais próprios e não as respostas completas do Google. Dados provenientes de outras fontes legítimas devem manter `fonte_id` e evidências próprias; nunca rotular informação do Google como se viesse da Receita ou de um site institucional.

Configuração: habilitar faturamento e Places API (New) em um projeto Google Cloud; restringir chave no backend e no uso permitido da API; usar máscaras de campos explícitas (`X-Goog-FieldMask`), em vez de `*`; aplicar limites de consumo por usuário, período e método, com bloqueio ao exceder o orçamento. A cobrança considera a SKU de maior nível incluída nos campos solicitados. Segurança e atribuições devem ser verificadas antes de publicar a integração.

Modalidade manual e automática: pesquisas no Google pelo painel serão **manuais/sob demanda** na primeira versão da integração. A execução automática já prevista no projeto permanece para **dados oficiais e scraping permitido**. Uma varredura automática ou armazenamento sistemático de conteúdo Google não está aprovado e exigiria reavaliação jurídica/contratual e orçamentária; o agendamento do sistema não altera permissões de uso da fonte.

Critérios de aceite específicos: consulta de farmácias em uma cidade; exibição de resultados e link Google Maps com atribuições corretas; consulta de detalhes quando selecionados; controle de faltas de resultados; impossibilidade de gravar/exportar contatos restritos do Google; associação manual por `place_id`; orçamento/quotas registrados; rejeição de termos fora de escopo; teste de falha 403/429 sem fallback para scraping Google Maps. Piloto deverá medir quantidade de consultas, custo por consulta e relevância dos resultados, sem confundir isso com aumento comprovado da cobertura cadastral.

Fontes oficiais para validação da implementação:

- Places Text Search (New): https://developers.google.com/maps/documentation/places/web-service/text-search
- Places Nearby Search (New): https://developers.google.com/maps/documentation/places/web-service/nearby-search
- Place Data Fields (New): https://developers.google.com/maps/documentation/places/web-service/data-fields
- Places Policies: https://developers.google.com/maps/documentation/places/web-service/policies
- Places Usage and Billing: https://developers.google.com/maps/documentation/places/web-service/usage-and-billing
- Google, Places Insights para leads: https://developers.google.com/maps/architecture/places-insights-sales-leads
- Places Insights (disponibilidade do Brasil): https://developers.google.com/maps/documentation/placesinsights/cloud-setup

Ressalva de negócio: se a exigência for **gravar permanentemente todos os contatos das farmácias apresentados pelo Google Maps**, o objetivo não é atendido nos termos normais da Places API. É necessário obter uma licença/solução expressamente compatível ou coletar os mesmos dados de fontes independentes cujo uso e armazenamento sejam permitidos. Não afirmar que o simples aparecimento de um número no Google permite incluí-lo no Supabase.

7.7 Estratégia mult fontes de prospecção - decisão de arquitetura (versão 1.5)

A plataforma terá um **cadastro mestre por CNPJ** e **conectores especializados independentes**, ao invés de um único robô central ou da extração em massa do Google Maps. Cada fonte fornece uma função diferente: cobertura cadastral, enriquecimento de contatos,

confirmação de atividade, localização complementar ou pesquisa contextual. **Disponibilidade pública não equivale a licença de reutilização:** as colunas abaixo são orientações técnicas, não parecer jurídico definitivo.

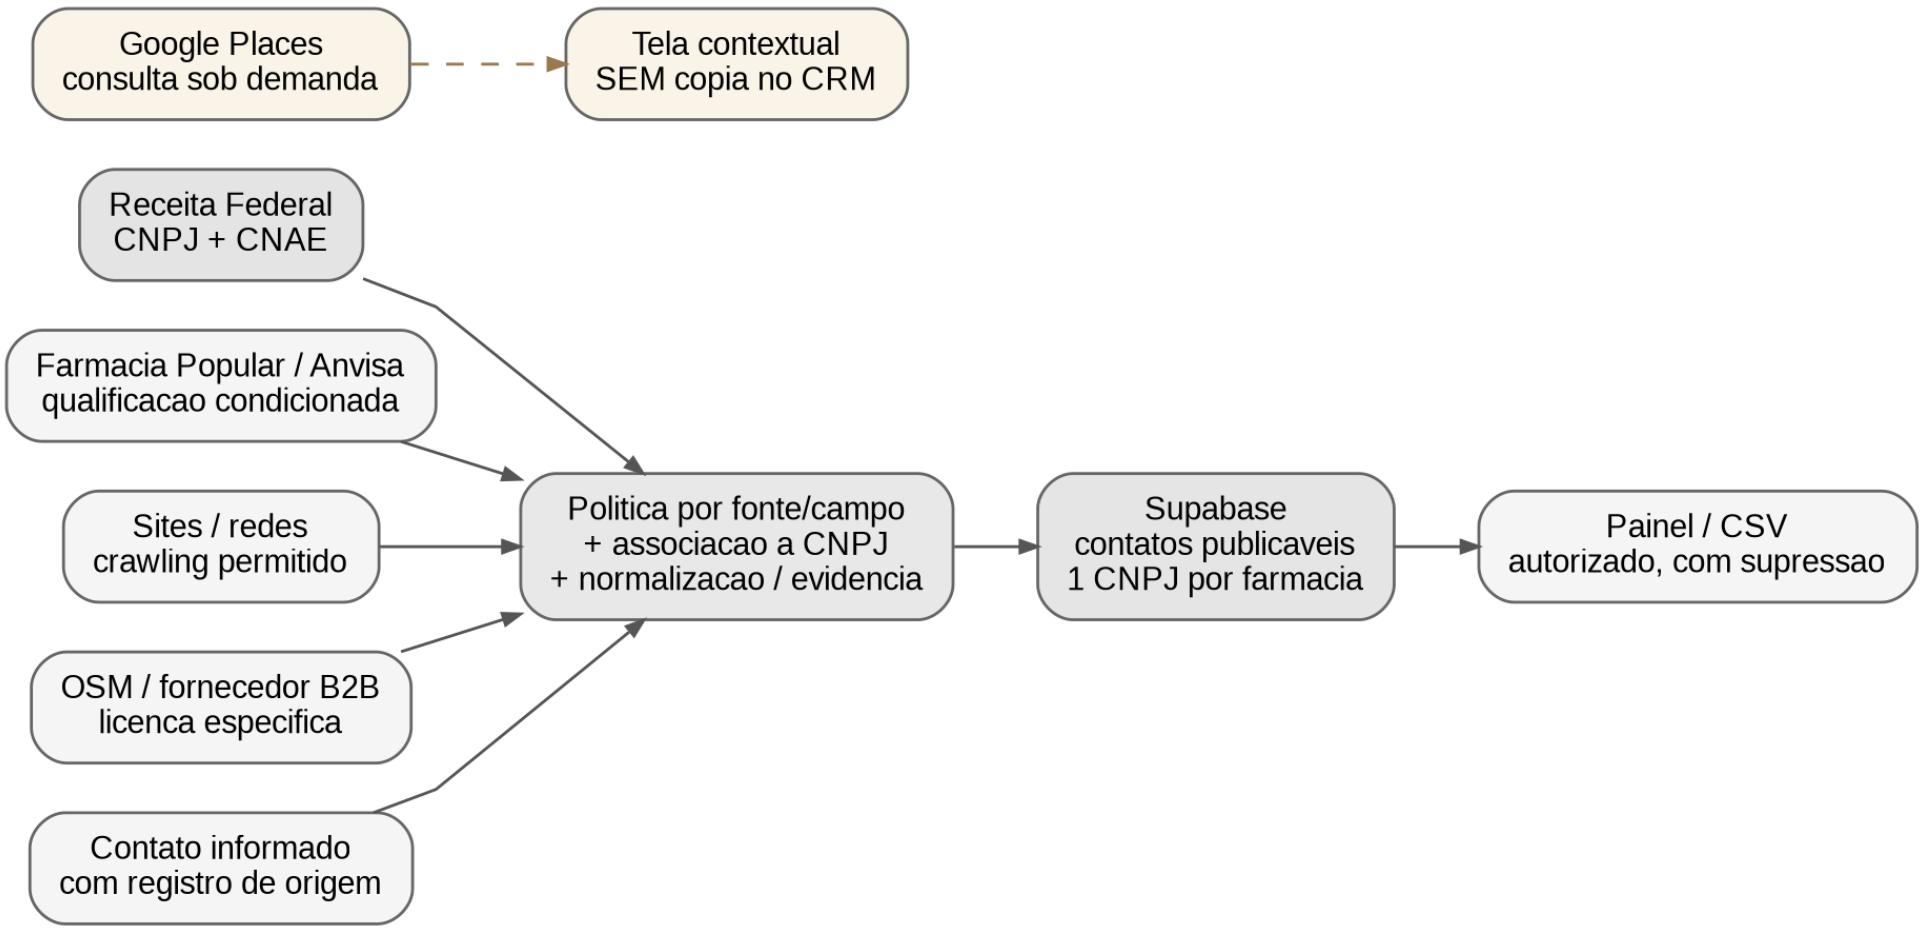


Figura 6 - Fontes permitidas, política de uso e dados comerciais

Fonte concreta	Papel no produto	Persistência no Supabase	Pri.	Gate antes da ativação
Receita Federal - dados abertos de CNPJ	Universo de farmácias, CNPJ, CNAE, situação cadastral, endereço e contatos declarados	**Sim**, para campos de uso permitido, com fonte, competência, tratamento LGPD e revalidação	P0	Validar layout/versão e regras de uso; processar o recorte em vez de importar todo o país
Sites institucionais de farmácias	E-mails de contato, telefone, links públicos de WhatsApp e redes	**Condicionada**: coleta e reutilização autorizadas por domínio, finalidade e canal	P0	Confirmar que o domínio é da farmácia; política de acesso e SSRF; contato publicado não garante opt-in
Localizadores de redes e franquias	Telefones/unidades por loja, com vínculo empresa-filial	**Condicionada** a cada domínio e licença; separação filial x matriz	P1	Teste de parser, autorização de coleta e associação unitária por CNPJ/endereço
Farmácia Popular - lista de participantes	Qualificação do estabelecimento e cruzamento de credenciamento	**Sob validação** das colunas reais e condições de reutilização da lista pública	P1	Download versionado e conferência de presença/qualidade do identificador CNPJ
Anvisa - consultas de farmácias/drogarias	Indicador de autorização/regularidade, não fonte geral de telefones	**Sob validação** de mecanismo e uso, não presumir API ou extração em lote	P1	Consulta oficial e documentação de permissão para processamento sistemático; filiais exigem cuidado
OpenStreetMap	Dados geográficos e eventualmente contatos/site declarados por contribuidores	**Possível conforme ODbL**, atribuição, obrigações de base derivada e tratamento de dados	P2	Revisar impacto ODbL no dataset/redistribuição e origem de cada atributo; evitar limites de infraestrutura comunitária
Fornecedores B2B licenciados	Complementar contatos quando houver cobertura insuficiente	**Conforme contrato explícito**, retenção, uso comercial e direitos de exportação	P2	Contrato, documentação de origem, licença por campo e tratamento LGPD aprovados
Informação fornecida pela farmácia / comercial	Correção e confirmação operacional de canal empresarial	**Sim, se a finalidade e base legal forem adequadas**, com origem e auditoria	P0	Registrar quem informou, quando, finalidade e evidência de comunicação/consentimento quando necessário

Fonte concreta	Papel no produto	Persistência no Supabase	Pri.	Gate antes da ativação
Google Places API (New)	Busca e consulta contextual no Google Maps, sob demanda	**Por padrão só `place_id`**; conteúdo de ficha sem cópia permanente de CRM	P1 cond.	Aprovação de uso, cobrança, atribuições, máscaras de campo e fluxo sem exportação do conteúdo restrito
Outras bases regionais/municipais	Identificar estabelecimentos adicionais ou sinais de licenciamento	**A definir caso a caso**, mediante instrumento legal e licença concreta	P2	Primeiro catalogar fonte, dataset, finalidade e política; não criar crawler genérico de órgãos

Evidência pesquisada em 23/10/2026: o Ministério da Saúde disponibiliza uma lista atualizada de participantes do Farmácia Popular (02/10/2026), mas o layout do arquivo não foi validado neste projeto; a Anvisa oferece consulta pública de farmácias e drogarias autorizadas, não foi identificada aqui autorização geral de extração em massa. OpenStreetMap declara ODbL com atribuição e condições de compartilhamento de bases derivadas. O Google Places permite armazenar o `place_id` sob exceção específica, mas proíbe pré-busca e armazenamento geral de conteúdo de Places sob termos padrão. Referências oficiais estão no item 16.3.

7.8 Contrato único de conector e políticas por campo

Interface lógica proposta: `SourceConnector.discover(scope)`, `SourceConnector.fetch(cursor)`, `SourceConnector.parse(payload)`, `SourceConnector.normalize(observation)`, `SourceConnector.check_permissions(action, field)` e `SourceConnector.checkpoint(state)`. Nem todas as fontes fazem crawling: Receita e Farmácia Popular são importadores de arquivo; fornecedor usa arquivo/API contratada; input humano passa pela FastAPI; Google Places usa API de apresentação sob demanda em módulo próprio, **fora do pipeline de contatos persistidos**.

Campos mínimos de metadados: `fonte_id`, `tipo_fonte`, `licenca_versao`, `contrato_referencia`, `documentacao_url`, `permitir_coleta`, `permitir_persistencia`, `permitir_exibicao`, `permitir_exportacao`, `restricao_canal`, `retencao_dias`, `capturado_em`, `competencia_dataset`, `revisado_em`, `aprovado_por` e `estado_aprovacao`. Permissões e finalidades sensíveis devem ser modeladas também **por tipo de campo**, pois um dataset pode permitir armazenar CNPJ e restringir outro atributo.

Portão de publicação (fail-closed): observação bruta -> fonte/termos válidos -> dado permitido -> associação com CNPJ confiável -> verificação técnica -> verificação de vínculo -> classificação pessoal/empresarial -> supressão e canal -> consolidação -> disponibilização/exportação autorizada. Em caso de fonte pendente, contrato expirado, CNPJ ambíguo, erro de parser ou política indefinida: **quarentena**, com motivo e revisão humana. A aplicação não deve “herdar” a permissão de um contato de uma outra fonte quando o próprio valor só foi observado numa fonte restrita.

7.9 Política de persistência e segregação Google

- **`core.estabelecimento`** recebe dados da Receita e demais fontes com uso legítimo, não clones da resposta do Google.
- **`core.contato`** recebe apenas telefones/e-mails cujo `fonte_id` e política autorizem aquela persistência e finalidade. Exemplo: número identificado em `mailto:/tel:` de site institucional cuja coleta foi autorizada, ou campo do cadastro oficial, com atribuição de origem.
- **`core.google_place_ref`** admite apenas `place_id` e vínculo revisado a um CNPJ já conhecido por fonte independente. Não persistir JSON integral de Place Details, telefone ou website exclusivo da resposta Google, nem atributos em logs.
- **O scraper não deverá transformar uma resposta Google em lista de sites para crawling como forma de contornar os termos**. Fontes usadas no cadastro mestre precisam ser descobertas e justificadas de maneira independente.
- Se não existir fonte independente habilitada com telefone: exibir “Contato não confirmado na base própria”; oferecer consulta Google sob demanda na interface permitida, sem exportá-lo como dado de CRM.

7.10 Resolução de conflitos e prioridade de publicação

1. CNPJ de 14 dígitos, validado, identifica estabelecimento; **raiz de 8 dígitos não deduplica filiais**.
2. A fonte oficial governa identidade cadastral (CNPJ, CNAE e situação); demais fontes geram observações sem substituir silenciosamente esses dados.
3. Telefones iguais, após normalização E.164, consolidam-se como um único contato por estabelecimento e tipo, mantendo **todas** as evidências independentes. Telefones diferentes coexistem, com classificação de uso e atualidade.
4. Dados de rede/franquia podem pertencer à central; usar marca `compartilhado` e não replicar como contato confirmado de cada filial.
5. Conferência sintática de telefone, WhatsApp publicado ou MX do e-mail **não comprova entrega, titularidade nem permissão para contato comercial**.
6. Exportar apenas evidências autorizadas e atuais, com supressão aplicada e regra de canal aprovada. A ordem de prioridade (fonte oficial, site confirmado, informação da farmácia, fornecedor etc.) é **proposta**, ajustável após precisão amostral.

7.11 Piloto mult fontes e metas de verificação

Executar um piloto com uma UF a definir e uma amostra estratificada de farmácias independentes e redes. Rodar: (A) Receita isolada; (B) Receita + sites autorizados; (C) + Farmácia Popular/Anvisa com permissões verificadas; (D) canais fornecidos por parceiros/fornecedor contratado; (E) Google Places somente em consulta contextual. Registrar: CNPJs únicos,

contatos adicionais únicos permitidos, contatos em quarentena, cobertura por UF, custo por contato elegível, rejeições, conflito de fontes e tempo de revalidação. Comparar ganho **incremental**; não somar totais brutos de fontes como se fossem novos leads.

Gate de aceite: uma mesma farmácia pode possuir contatos vindos de três fontes legítimas sem gerar três leads; perda de uma fonte não elimina as demais; revogação do direito de uso de uma fonte impede novas exportações afetadas; conteúdo Google restrito não persiste; todo campo comercial exportado possui `fonte_id` e justificativa de uso. Somente após esse piloto devem ser aprovadas metas nacionais e investimentos de APIs adicionais.

8. Modelo de dados Supabase / PostgreSQL

8.1 Modelo lógico de entidades

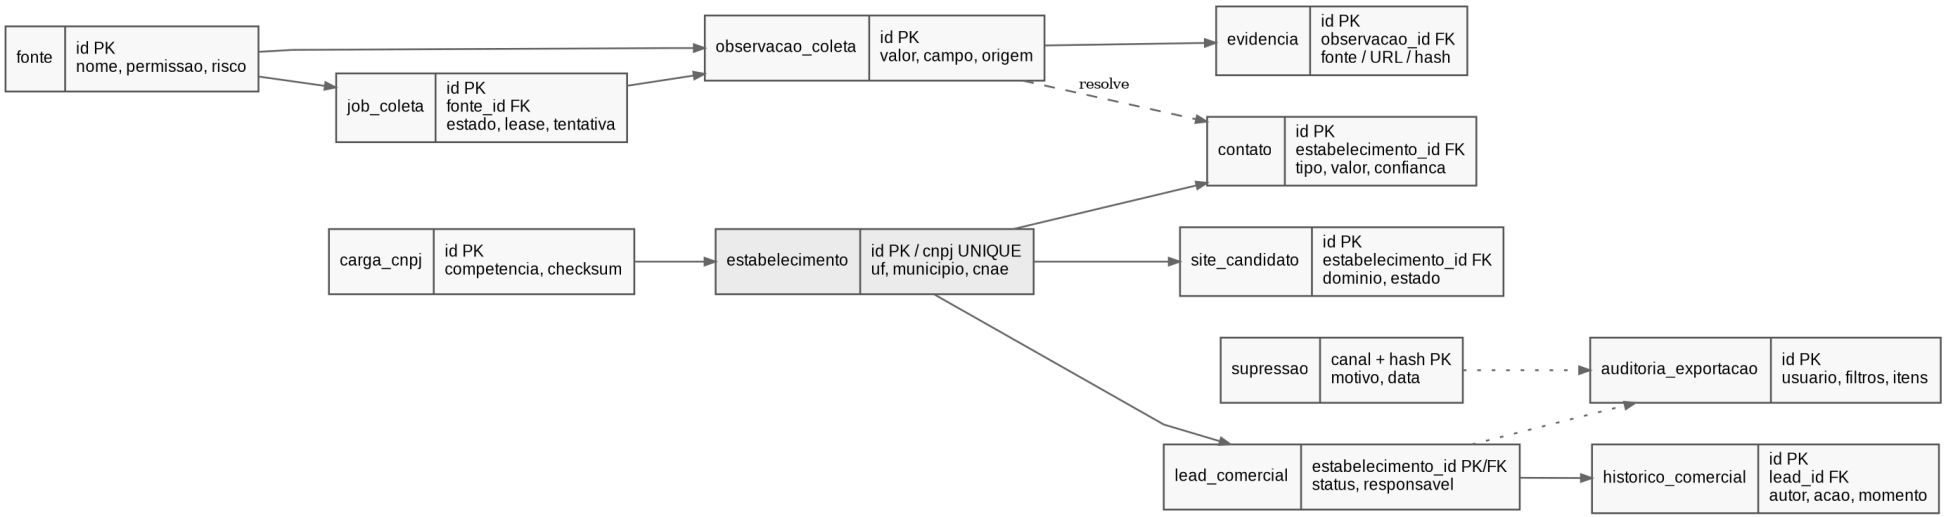


Figura 7 - Relacionamentos principais (visão simplificada)

Observação: é um modelo lógico, não DDL executável. O diagrama omite campos operacionais, integridade e cardinalidades detalhadas, descritos a seguir.

8.2 Schemas propostos

Schema	Acesso e finalidade
`ingest`	Lotes e metadados de importação, staging controlado
`core`	Cadastro mestre, contatos consolidados, candidatos e ligações
`coleta`	Fontes, jobs, observações, evidências e revisão
`comercial`	Status, responsáveis, notas, atividades e supressão
`audit`	Eventos de operação e exportações append-only
`api` (opcional)	Views/RPC explicitamente expostas, com permissões mínimas

Proteção de acesso: schemas internos não devem ser expostos pela Data API por padrão. O backend usa usuário PostgreSQL com permissões restritas. Caso exponha `api` para frontend, configurar corretamente GRANT e RLS, inclusive em views; testar acesso `anon` e `authenticated`. Credencial de serviço ou senha de conexão nunca é entregue ao navegador.

8.3 Entidades, chaves e campos relevantes

Entidade	Chave e campos centrais	Restrições/observações
`ingest.carga_cnpj`	id, competencia, arquivo, checksum, layout, contagens, estado	Evitar promoção sem reconciliação
`ingest.rejeicao_carga`	id, carga_id, registro_referencia, erro	Volume e retenção a dimensionar
`core.estabelecimento`	id UUID, cnpj CHAR(14), cnpj_basico, CNAE, UF, município IBGE, endereço, situação, snapshot	UNIQUE(cnpj), índices por UF/município
`core.grupo_empresarial`	id, nome_normalizado, método_agrupamento	Não implica fusão
`core.site_candidato`	id, estabelecimento_id, dominio, origem, estado, score_vinculo	Revisão de ambiguidade
`coleta.fonte`	id, nome, tipo, licença/termos, finalidade, risco, ativa, revisada_em, estado_aprovacao	Nenhuma fonte desconhecida roda
`coleta.fonte_politica_campo`	fonte_id, tipo_campo, acao, permitido, validade, fundamento, revisao	`UNIQUE(fonte_id,tipo_campo,acao)`; negar por padrão

Entidade	Chave e campos centrais	Restrições/observações
`ingest.dataset_externo`	id, fonte_id, versao, checksum, origem_url, importado_em, situacao	Versionar Farmácia Popular, OSM ou CSV contratado quando permitido
`coleta.conector_execucao`	id, fonte_id, job_id, adaptador_versao, cursor, aceitos, rejeitados	Estado e métricas por fonte, sem substituir `job_coleta`
`coleta.conflito_fonte`	id, estabelecimento_id, campo, evidencias, motivo, estado, revisado_por	Revisão de divergências e CNPJ ambíguo
`coleta.job_coleta`	id, fonte_id, partição, estado, idempotency_key, `origem`, `solicitado_por`, `agenda_id`, janela_logica, tentativas, lease, heartbeat, checkpoint	UNIQUE lógico por tarefa/janela; `origem` = manual ou automatico
`coleta.agenda_coleta`	id, fonte_id, tipo_job, parametros_json, periodicidade, horario_local, timezone, ativa, politica_atraso, proxima_execucao_em, ultima_execucao_em, criado_por, alterado_em	Só admin edita; reserva e avanço da agenda atômicos; `timezone` IANA
`coleta.observacao_coleta`	id, job_id, fonte_id, campo, valor_bruto, normalizado, timestamp	Dado observado, ainda não consolidado
`coleta.evidencia`	id, observacao_id, URL, snippet limitado, hash, storage_key, data	Acesso privado; retenção
`core.contato`	id, estabelecimento_id, tipo, valor, flags qualidade, score, revisao_em	UNIQUE(estabelecimento,tipo,valor)
`core.contato_observacao`	contato_id, observacao_id, algoritmo_versao	N:N, rastreia por que o contato existe
`comercial.lead_comercial`	estabelecimento_id, status, responsavel_id, atualizado_em	Isolado de writes de scraper
`comercial.historico_comercial`	id, estabelecimento_id, autor_id, campo, antes/depois, data	Append-only em aplicação
`comercial.supressao`	canal, valor_hmac, motivo, registrado_em	HMAC de contato normalizado; sem chave no frontend
`audit.auditoria_exportacao`	id, usuario_id, filtros, quantidades, finalidade, criado_em	Nunca gravar cópia desnecessária de todos os contatos
`audit.evento_sistema`	id, ator, acao, objeto, resultado, data, correlation_id	Retenção e mascaramento
`core.usuario_perfil`	auth_user_id, papel, ativo, criado_em	FK lógica/segura para Supabase Auth
`core.google_place_ref` (opcional)	estabelecimento_id, place_id, vinculado_em	Apenas referência/identificador, sem copiar campos de Places sob restrição

Entidade	Chave e campos centrais	Restrições/observações
`audit.google_places_consulta` (condicional)	id, usuario_id, endpoint, fieldmask, sku_prevista, custo_estimado, status, criado_em	Guardar apenas metadados internos de uso/custo, sem payload restrito de Places

8.3.1 Exemplo de persistência de múltiplas origens (regra obrigatória)

Um mesmo CNPJ recebe telefone A na Receita e telefone A no site confirmado; os dois registros devem preservar suas evidências próprias, mas `core.contato` exibe **uma única linha** para telefone A. Se o telefone B aparecer apenas na ficha Google, o telefone B **não** é inserido em `core.contato` pelo conector Places. Se um contato provém de CSV contratado cuja licença impede exportar, ele pode ser exibido ou mantido somente se essas operações estiverem explicitamente permitidas; o exportador precisa filtrar o uso por fonte/atributo, não apenas por `score`.

A trilha `coleta.fonte -> coleta.observacao_coleta -> core.contato_observacao -> core.contato` deve permitir demonstrar a independência real de cada evidência. A política de armazenamento do Supabase não altera os direitos de terceiros sobre os dados.

8.4 Índices, transações e migrations

- Índice único no CNPJ completo e nos contatos normalizados por estabelecimento/tipo.
- Índice composto `(uf, municipio_codigo)` e índices de datas para revalidação.
- `pg_trgm` para pesquisa aproximada se a medição justificar; `PostGIS` apenas se houver consulta geoespacial.
- Chaves estrangeiras, `NOT NULL` e `CHECK` para estados críticos, datas e scores.
- Inserções em lote e `INSERT ... ON CONFLICT` para reprocessamentos; observações com identidade de evento para evitar duplicidade por retry.
- Índice composto sobre agendas ativas e `proxima_execucao_em`; unique por chave de idempotência de job. Claims do scheduler com bloqueio de linha, sem executar scraping dentro da transação.
- Alembic como fonte de migrations da aplicação; scripts SQL revisados para grants, schemas, extensões e RLS. Nunca usar `db push` destrutivo sem revisão de diff e plano de rollback.
- Separar ambiente de testes e produção; toda mudança de banco deve passar por CI e snapshot/backup quando compatível com o risco.

8.5 Volume e estratégia para base nacional

O processamento completo de arquivos CNPJ nacionais pode ocupar dezenas de gigabytes e demandar muito mais espaço temporário do que a base filtrada de farmácias. **Não colocar todo o ZIP e todos os registros nacionais na base operacional do Supabase sem dimensionamento.** Preferir download/streaming em worker apropriado, validação local do

layout, filtro de estabelecimentos e `COPY` apenas do recorte necessário. Avaliar custo de compute, armazenamento e egress após um ensaio com uma UF; armazenar manifestos e estatísticas de carga para reprodutibilidade.

8.6 Supabase Auth, Storage e backup

- **Auth:** login de usuários internos com identidade gerenciada pelo Supabase. Papéis de negócio no banco da aplicação, não em metadados de usuário editáveis pelo próprio usuário.
- **Storage:** bucket privado `coleta-evidencias` (nome sugerido). Guardar apenas artefatos autorizados, com objetos identificados por chave imutável e política de retenção; preferir snippets/metadata a HTML completo quando possível.
- **Segredos:** senha Postgres, token de serviço e chaves de fontes sob secret manager/variáveis protegidas no servidor. Chaves públicas do frontend não concedem acesso administrativo.
- **Backups:** contratar/verificar o nível apropriado de backups PostgreSQL; realizar restauração de teste. Backups automáticos do banco **não incluem os próprios arquivos armazenados no Supabase Storage**; esses exigem recuperação separada.
- **Conexões:** cuidar de limites de pool/conexões; workers não criam conexão por registro. Usar pool com teto configurado e transações curtas.

9. Contratos de API e navegação do painel

9.1 Princípios de API

API REST versionada (`/v1`), JSON, datas ISO 8601 UTC, paginação por cursor quando adequada, filtros documentados, erros padronizados com código e `request_id`, limites de taxa e validação de entrada. Apenas o backend com permissões adequadas escreve em dados internos; o usuário final não acessa PostgreSQL diretamente.

9.2 Endpoints previstos

Método e caminho	Função	Papel mínimo sugerido
`GET /v1/estabelecimentos`	Busca com filtros e paginação	comercial
`GET /v1/estabelecimentos/{id}`	Detalhes, contatos e evidências permitidas	comercial
`GET /v1/contatos/{id}/evidencias`	Histórico e classificação	comercial
`PATCH /v1/leads/{estabelecimento_id}`	Status, responsável, observações	comercial
`POST /v1/leads/{id}/atividades`	Registrar interação manual	comercial

Método e caminho	Função	Papel mínimo sugerido
`GET /v1/jobs`	Histórico e estado de jobs	operador
`POST /v1/jobs`	Disparar coleta **manual**; responde 202 com `job_id`	operador
`POST /v1/jobs/{id}/reprocessar`	Retomar/reexecutar com idempotência	operador
`POST /v1/jobs/{id}/cancelar`	Solicitar cancelamento auditável do job	operador
`GET /v1/agendas`	Listar agendas, próxima e última execução, estado	operador
`POST /v1/agendas`	Cadastrar recorrência de coleta	admin
`PATCH /v1/agendas/{id}`	Alterar parâmetros, suspender ou reativar agenda	admin
`GET /v1/agendas/{id}/execucoes`	Consultar jobs originados pela agenda	operador
`GET /v1/fontes`	Consultar fontes, termos e permissões por campo	operador
`GET /v1/fontes/{id}/politicas`	Mostrar permissões de persistência/exibição/exportação por tipo de campo	operador
`PATCH /v1/fontes/{id}`	Aprovar, suspender ou atualizar contrato, escopo e licença	admin
`POST /v1/importacoes/datasets`	Iniciar importação autorizada de Farmácia Popular/CSV contratado/OSM com versão	operador
`GET /v1/qualidade/fontes`	Cobertura incremental, custo, frescor e conflitos por fonte	gestor
`GET /v1/revisoes/conflitos`	Listar divergências de dados e vínculos entre fontes	revisor
`GET /v1/integracoes/google/places/buscar` (P1 condicionado)	Pesquisar farmácias por cidade/termo/raio com controle de custo	operador
`GET /v1/integracoes/google/places/{place_id}` (P1 condicionado)	Consulta transitória dos detalhes de local selecionado	operador
`POST /v1/integracoes/google/places/vinculos` (P1 condicionado)	Vincular referência `place_id` a estabelecimento após revisão	revisor
`GET /v1/integracoes/google/places/consumo` (P1 condicionado)	Auditoria de quota e custo das consultas	admin
`POST /v1/revisoes/vinculos`	Aprovar/rejeitar site candidato	revisor

Método e caminho	Função	Papel mínimo sugerido
`POST /v1/exportacoes`	Criar exportação filtrada e auditada	gestor
`GET /v1/exportacoes/{id}`	Estado/arquivo temporário autorizado	gestor
`POST /v1/supressoes`	Registrar bloqueio de contato/canal	privacidade
`GET /v1/metricas/cobertura`	Indicadores por UF, fonte e período	gestor
`GET /health` e `/ready`	Saúde/liveness e disponibilidade dependências	infraestrutura

Importante: estes caminhos são contrato proposto e deverão ser consolidados no OpenAPI ao implementar; a lista não corresponde a endpoints já existentes.

9.3 Telas previstas do sistema

1. **Login e acesso:** autenticação, sessão e bloqueio conforme perfil.
2. **Visão geral:** total de estabelecimentos, contatos por nível de confiança, cobertura UF e últimas coletas.
3. **Tabela de leads:** pesquisa, filtros, paginação, seleção e exportação autorizada.
4. **Detalhe do estabelecimento:** cadastro oficial, contatos, data, tipo de verificação e evidências.
5. **Operação comercial:** status, responsável, observações, histórico e atividades.
6. **Monitor de coletas:** botão **Nova coleta** (manual, para operador), seleção de fonte/região, confirmação, jobs com origem manual/automática, filtros por fonte/região, erros, cancelamento autorizado e reprocessamento. **Aba Agendamentos:** recorrências, próxima execução, última execução e habilitação/pausa pelo administrador.
7. **Revisão de sites:** vínculos sugeridos, sinais usados e decisão humana.
8. **Administração:** usuários, papéis, fontes, regras e política de supressão.
9. **Auditoria e indicadores:** exports, alterações, qualidade, frescor e falhas.
10. **Buscar no Google Maps (condicionado):** pesquisa de farmácias, abertura de ficha de detalhes, referência por `place_id` e monitor de consumo; sem exportação nem persistência de campos restritos como leads.

9.4 Matriz de papéis sugerida

Ação	Admin	Operador	Revisor	Comercial	Gestor	Privacidade
Consultar leads permitidos	S	S	S	S	S	Conforme caso

Ação	Admin	Operador	Revisor	Comercial	Gestor	Privacidade
Criar/re-processar jobs manu-almente	S	S	N	N	N	N
Criar/ alterar/ pausar agendas automáti-cas	S	N	N	N	N	N
Consultar agendas e histórico de coletas	S	S	N	N	Conforme po-lítica	N
Aprovar site candi-dato	S	S	S	N	N	N
Alterar sta-tus/nota comercial	S	N	N	S	S	N
Exportar contatos	S	N	N	N	S	Conforme po-lítica
Aplicar su-pressão	S	N	N	N	N	S
Adminis-trar fontes/ papéis	S	Conforme de-legação	N	N	N	N
Buscar e consultar Places sob demanda (se apro-vado)	S	S	S	Conforme po-lítica	S	N
Vincular `place_id` ao CNPJ após revi-são	S	S	S	N	N	N
Consultar auditoria	S	Parcial	N	N	Parcial	Conforme fi-nalidade

`S` e `N` são propostas. A matriz final exige aprovação do negócio e testes por papel, inclusive registros de outros responsáveis se houver segregação por vendedor.

10. Segurança, privacidade e conformidade

10.1 Modelagem inicial de ameaças

Ameaça	Impacto	Controle planejado
Scraper acessa endereço interno por URL maliciosa	Vazamento de serviços internos	Bloquear IPs privados/link-local, DNS e redirecionamentos
Chave administrativa exposta no navegador	Leitura/escrita não autorizada	Segredos só em backend; scans de CI
RLS/GRANT incorreto	Vazamento entre perfis	Schemas privados, testes de acesso negativos
HTML malicioso exibido no painel	XSS	Renderizar como texto, sanitização, CSP
Vendedor exporta contatos suprimidos	Descumprimento de opt-out	Filtro central obrigatório na API
Dados incorretos vinculados a CNPJ	Abordagem errada	Review manual, provas e score calibrado
Processamento repetido causa duplicidade	Erro comercial e custo	Idempotência, locks e UNIQUE
Arquivos de evidência divulgados	Exposição de dados pessoais	Bucket privado, URLs temporárias e retenção
Excesso de jobs e custo	Indisponibilidade/sobrecusto	Quotas, timeouts, alarmes e limites por fonte
Uso da Places API para montar diretório/exportação permanente ou chave Google exposta	Violação contratual, cobranças indevidas e bloqueio	Isolamento por `place_id`, chave restrita, controle de quota e testes negativos de persistência
Perda ou corrupção do banco	Interrupção e perda de históricos	Backup, restauração testada, migrations com rollback

10.2 Governança de dados

Cadastrar finalidade e condição de uso por fonte; documentar teste de legítimo interesse quando aplicável e revisá-lo com responsável jurídico; disponibilizar canal para correção, oposição ou exclusão; conservar o mínimo necessário e evitar coleta indiscriminada de dados pessoais. Aplicar a supressão antes da exportação e de qualquer integração. O tratamento público e a prospecção comercial requerem avaliação jurídica contextual: o fato de um contato ser público não estabelece autorização irrestrita para qualquer abordagem.

10.3 Restrições externas relevantes

A API Places do Google tem regras específicas de armazenamento e cache: o `place_id` é exceção explícita, mas isso não autoriza persistir indiscriminadamente seus demais campos em um banco de prospecção. As Business Profile APIs gerenciam perfis próprios/

autorizados e **não fazem parte do escopo atual**; para descobrir farmácias de terceiros, utiliza-se a Places API apenas sob as condições contratadas. O uso de dados de Places em telas requer observar as regras de atribuição aplicáveis. O Instagram e o WhatsApp têm políticas próprias para API e comunicação comercial. As regras e contratos devem ser verificados na implementação, não inferidos a partir de práticas de terceiros.

10.4 Política de retenção sugerida para aprovação

Categoria	Política inicial sugerida	Observação
Cadastro oficial consolidado	Até substituição e exigências de rastreabilidade	Base cadastral pública de PJ; reavaliar dados pessoais
Observações/evidências mínimas	12 meses, com reavaliação	Justificar necessidade e direitos
HTML bruto temporário	Até 90 dias, caso armazenado	Reduzir ao mínimo; acesso restrito
Logs técnicos sem valores sensíveis	90 dias para operação inicial	Ajustar custos e política
Auditoria de exportações	Período definido com jurídico e negócio	Não definir retenção arbitrária como obrigação legal
Supressões	Enquanto necessário para evitar nova abordagem	HMAC com chave rotacionada sob procedimento

Pendente: homologar prazos, bases legais e procedimentos de exclusão antes de operar com contatos pessoais em produção.

11. Testes, qualidade e homologação

11.1 Estratégia de testes por camada

Camada	Testes	Evidência esperada
Parsers/normalização	Unitários com fixtures HTML, CNPJ, telefones, e-mails	Relatório pytest
Ingestão oficial	Contrato de layout, checksum e reconciliação por UF	Manifesto e contagens
Scraping	Mock HTTP, robots, delays, bloqueio, timeouts, JS	Logs e testes de integração
Jobs	Idempotência, claim concorrente, lease e falha forçada	Ausência de job duplicado
PostgreSQL	Constraints, migrations, rollback, RLS e permissões	SQL testado em homologação
API	Contrato OpenAPI, validação, auth, autorização e paginação	Relatório de integração

Camada	Testes	Evidência esperada
Frontend	E2E das rotas críticas, acessibilidade, filtros e alterações	Relatório Playwright
Places API (P1 condicionado)	Termos/raio, FieldMask, place_id, cobrança, atribuição, 403/429 e bloqueio de persistência/exportação	Fixtures/mock de API e testes de integração sob quota controlada
Segurança	SSRF, XSS, exposição de credenciais, rate limit	Testes negativos
Operação	Backup/restore, alerta, indisponibilidade de fonte, fila	Runbook executado

11.2 Casos de teste prioritários

ID	Cenário	Resultado esperado
TC-001	Importar mesmo arquivo CNPJ duas vezes	Sem duplicação, mesma quantidade elegível
TC-002	CNPJ inválido em staging	Registro rejeitado com motivo
TC-003	Filiais com raiz igual e CNPJ diferente	Dois estabelecimentos mantidos
TC-004	Layout oficial alterado	Carga bloqueada e alerta
TC-005	Fonte responde 429 com `Retry-After`	Aguarda/reagenda dentro da política
TC-006	Fonte declara caminho proibido	Spider não requisita caminho
TC-007	URL redireciona para IP privado	Requisição bloqueada
TC-008	Job perde worker no meio da coleta	Lease expira, retoma sem duplicar
TC-009	Site da rede mostra contato central	Não atribuir automaticamente a todas as filiais
TC-010	E-mail tem MX mas não vínculo confirmado	Não classificar como contato confirmado
TC-011	Nova coleta de lead já negociado	Status, responsável e notas preservados
TC-012	Usuário comercial tenta criar job	Acesso negado
TC-013	Usuário comum tenta consultar dado não permitido	Acesso negado no backend e banco exposto
TC-014	Exportar contato suprimido	Contato ausente e exportação auditada
TC-015	Repetir importação de evidência idêntica	Sem observações duplicadas indevidamente

ID	Cenário	Resultado esperado
TC-016	Storage privado acessado sem permissão	Download bloqueado
TC-017	Restore de backup em homologação	Dados essenciais íntegros e teste documentado
TC-018	Spiders param de encontrar telefones	Alerta de variação de preenchimento
TC-019	Filtro por UF/CNAE e paginação	Total e páginas consistentes
TC-020	Atualizar status comercial	Autor e mudança registrados no histórico
TC-021	Operador inicia coleta manual pelo dashboard	API retorna 202/job_id e job aparece como manual no monitor
TC-022	Operador clica duas vezes em Iniciar coleta	Nenhum job equivalente duplicado; exibe ID existente
TC-023	Admin configura agenda diária e tick atinge o horário	Um job automático é criado com agenda_id e parâmetros corretos
TC-024	Scheduler tick executado em paralelo por dois processos	Uma única ocorrência agendada e um job lógico
TC-025	Máquina fica desligada durante execução prevista	Política de atraso aplicada na retomada sem avalanche
TC-026	Admin pausa agenda e inicia novo tick	Nenhum novo job automático da agenda pausada
TC-027	Usuário comercial tenta criar agenda	Acesso negado e evento auditado
TC-028	Coleta manual e automática da mesma partição simultaneamente	Uma fica deduplicada ou aguarda, sem executar dois crawls equivalentes
TC-029	Worker é interrompido após job automático	Lease expira, retoma idempotente e registros comerciais são mantidos

Cenários da descoberta Google (P1 condicionado): TC-G01: consulta “farmácias” por cidade usa API oficial e máscara restrita; TC-G02: seleção de `place_id` consulta detalhes atuais; TC-G03: retorno sem telefone mostra campo indisponível sem inventar contato; TC-G04: resposta Places não grava nome/telefone/endereço/site como lead; TC-G05: orçamento esgotado bloqueia chamadas; TC-G06: exibição atende atribuições; TC-G07: campos restritos não entram no CSV; TC-G08: duplicidade/ambiguidade de vínculo é submetida à revisão; TC-G09: erro 429 não aciona scraper Google Maps.

Cenários mult fontes obrigatórios: TC-MF-01: mesma farmácia presente em Receita e Farmácia Popular permanece um CNPJ único; TC-MF-02: mesmo telefone de duas fontes origina um contato e duas evidências; TC-MF-03: fonte sem licença/termos aprovados é blo-

queada; TC-MF-04: fonte autorizada apenas para exibição não é persistida/exportada; TC-MF-05: contato da Google Places não é gravado em `core.contato` ou nos logs; TC-MF-06: revogação de permissão bloqueia nova exportação; TC-MF-07: site com domínio não confirmado permanece em revisão; TC-MF-08: telefone de rede marcado como central não é atribuído como direto a cada filial; TC-MF-09: competência de dataset preservada em reimportação; TC-MF-10: fonte pausada não interrompe outros conectores; TC-MF-11: resultado OSM conserva atribuição e metadados de licença; TC-MF-12: importação de fornecedor sem contrato válido é rejeitada.

11.3 Critérios para aceite do piloto

- Carga oficial elegível reconciliada com a versão escolhida e diferenças documentadas.
- Pelo menos uma fonte autorizada com spider completo, testes de contrato, limitação por domínio e tratamento de erro.
- Catálogo mult fontes com matriz por campo e operação; validar pelo menos duas fontes **independentes** sem multiplicar o mesmo CNPJ/contato.
- Demostrar relatório incremental de contatos elegíveis por fonte e bloquear ingestão/exportação de origem restrita.
- Amostra de sites confirmados revisada por pessoa do negócio/QA; precisão reportada com tamanho da amostra e critério, não apenas porcentagem sem contexto.
- Banco Supabase com migrations reprodutíveis, contas separadas, segredos protegidos e testes negativos de acesso.
- Reprocessamento de jobs e de lotes não cria duplicidades nem sobrescreve gestão comercial.
- Um usuário operador inicia uma coleta manual pelo painel; o job aparece com origem e ID, progride em worker separado e retorna resultado consultável.
- Uma agenda ativa, configurada por admin, cria automaticamente um job no horário definido; agendas pausadas e ticks duplicados não produzem novas coletas indevidas.
- Política de janela perdida é demonstrada com máquina/agendador temporariamente indisponível, sem criação em massa de jobs atrasados.
- Painel mostra estabelecimentos, contatos com procedência, status e histórico.
- Exportação implementa supressão e registro de auditoria.
- Métricas mínimas de operação e restauração ensaiada antes de uso real.
- Aprovação jurídica e comercial para os canais efetivamente disponibilizados.

12. Planejamento de execução

12.1 Fases e entregáveis

Fase	Entrega principal	Gate de saída
F0 - Fundação	Decisões de escopo, cadastro de fontes, repositório, ambientes virtuais Python, scripts de execução, CI e projeto Supabase segregado	Acesso, licenças e ambientes validados
F1 - Base mestre	Pipeline Receita, dicionário, filtros, snapshots, migrations e contagens	Reconciliação validada no recorte-piloto
F2 - Descoberta e scraping	Conectores por fonte, site candidato, spiders, Playwright seletivo, ingestão complementar, evidências e fila única para jobs manuais/automáticos	Duas fontes independentes com ganho incremental comprovado e disparo manual pela API
F3 - Qualidade e deduplicação	Normalizadores, score, revisão humana e métricas	Precisão amostral e critérios atingidos
F4 - API e painel	Auth, RBAC, consulta, gestão de leads, exportação, **tela Nova coleta** e **gestão de agendas**, auditoria	UAT comercial, API, manual e agendas aprovados
F5 - Operação	Execução automática por cron/systemd timer/Agendador Windows, política de atrasos, reprocessamento, alertas, backups e escalonamento progressivo	Coleta automática demonstrada, runbooks, restore e custos medidos

A estimativa de 16 a 23 semanas do documento-base é apenas uma referência para um profissional experiente em tempo integral, não um compromisso de entrega. Ajustar após F0/F1, capacidade real da equipe, volume de dados e eventuais exigências jurídicas.

12.2 Backlog técnico inicial (primeiras entregas)

1. Criar repositório com convenções, `.env.example`, lint, pytest e proteção de secrets.
2. Criar projetos Supabase isolados (ao menos dev e produção), contas de serviço de menor privilégio e migrations.
3. Implementar schema mínimo de fontes, carga, estabelecimento e job, com constraints e índices.
4. Construir importador de recorte oficial em ambiente local, com validação de layout e relatório.
5. Importar recorte da UF piloto para o Supabase e medir custo/latência/volume.
6. Implementar mecanismo de job com reserva atômica, retry, idempotência, origem manual/automática e rastreabilidade.

7. Construir primeiro spider para um domínio cuja coleta esteja autorizada. 7a. Implementar matriz de fontes/campos/ações, com estado aprovado/pendente, importador da lista Farmácia Popular após verificação de colunas e regras, e endpoint para registro de contato informado pela empresa. 7b. Criar testes de separação de conteúdo Google e avaliação do ganho incremental de dados por origem.
8. Registrar observações/evidências, normalizar e relacionar a estabelecimento.
9. Criar endpoints de lista/detalhe e autenticação básica com papéis.
10. Criar tela de tabela de leads, ficha de detalhes, monitor de jobs e **botão Nova coleta**, sem executar crawling na API.
11. Criar `coleta.agenda_coleta`, os endpoints de administração da agenda e comando Python `scheduler tick` integrado a cron/systemd timer/Agendador Windows; validar atraso, pausa e duplicação.
12. Implementar trilha comercial, supressão, exportação controlada e testes de acesso.
13. Executar homologação ponta a ponta incluindo disparo manual e automático com dados amostrais e critérios de aceite.
14. Projetar integração Google Places P1 condicionada a aprovação de termos, cotas e orçamento; priorizar busca manual + detalhe transitório + `place_id`, sem copiar respostas restritas para a base de leads. Considerar Places Insights P2 se necessário.

12.3 Estrutura proposta de repositório

```
prospeccao-farmacias/
|-- pyproject.toml
|-- requirements.txt              # ou dependencias no pyproject.toml
|-- .env.example
|-- README.md
|-- docs/
|   |-- architecture/
|   |-- requirements/
|   |-- runbooks/
|   `-- governance/
|-- database/
|   |-- migrations/
|   `-- sql/                    # grants, policies, indices
|-- apps/
|   |-- api/                    # FastAPI, services, auth, schemas
|   `-- web/                    # React, TypeScript, Vite
|-- services/
|   |-- ingest_cnpj/            # arquivos oficiais, versao, filtro
|   |-- discovery/              # candidatos a sites e associacao
|   |-- connectors/             # importadores e adaptadores por fonte (Farmacia Popular,
CSV, OSM condicional)
|   |-- source_policies/        # licenca por fonte/campo, persistencia e exportacao
|   |-- google_integrations/     # Places Search/Details isolados, controle de quota (P1
condicionado)
|   |-- crawler/                # projeto Scrapy e spiders
|   |-- normalizer/             # Pydantic, phonenumbers etc.
|   |-- resolver/               # evidencias, identidade, score
|   `-- scheduler/              # agendas, tick, jobs, lease, retry
|-- shared/                     # modelos e configuracoes Python
|-- tests/
|   |-- unit/
|   |-- integration/
|   |-- contract/
|   |-- e2e/
|   `-- fixtures/
```

```
|-- ops/                        # scripts de inicio, tarefa agendada, systemd e cron
`-- .github/workflows/
```

12.4 Definition of Done

Uma tarefa está concluída quando o código foi revisado, tem testes adequados, migrations versionadas se houve alteração de esquema, logs sem dados sensíveis, documentação de configuração, evidência de execução em homologação e critério de aceite demonstrado. Funcionalidade que depende de permissão jurídica ou de fonte não aprovada não é considerada liberada para produção.

13. Operação, monitoramento e resposta a incidentes

13.1 Métricas mínimas e alarmes

Coletas: jobs criados, iniciados, finalizados, **origem manual/automática, taxa de atrasos das agendas, próximas execuções vencidas**, tempo por fonte, erros por categoria, requisições 429/403, páginas processadas, campos encontrados, queda abrupta de preenchimento, fila acumulada e leases expirados. Dados: total elegível por UF, contatos com evidência recente, contatos rejeitados, duplicidade, percentual em revisão e versões de carga. Aplicação: HTTP p50/p95, erros 5xx, tentativas de acesso negado, exportações e custo por período.

13.2 Procedimento operacional resumido

- **Falha de importação:** bloquear promoção, preservar versão anterior, comparar layout, abrir incidente e reprocessar após correção.
- **Quebra de spider:** pausar fonte, registrar amostra/fixture, corrigir parser e liberar após teste de contrato.
- **Supabase indisponível:** suspender novas coletas, armazenar apenas buffer limitado e seguro; reexecutar jobs idempotentes após retorno.
- **Vazamento/acesso indevido:** revogar segredos, bloquear exportação e seguir plano de resposta a incidentes com responsáveis legais.
- **Perda de dados:** restaurar em ambiente segregado, validar integridade e aplicar procedimento documentado de recuperação.
- **Estouro de orçamento:** interromper integrações pagas e suspender novos jobs por fonte até aprovação.

13.3 Capacidade e custos a validar

Não há dados suficientes para afirmar custo mensal de Supabase, servidor ou APIs. Integrações Google, se aprovadas, deverão ter cota, limites de orçamento e aferição de preço vigentes antes de ser ativadas. Medir no piloto: tamanho da base filtrada, volume de obser-

vações por estabelecimento, tamanho de evidências, conexões simultâneas, CPU/RAM por browser, throughput, egress e retenção. Projetar produção a partir dessas medidas; a plataforma não deve depender de créditos gratuitos ou quotas não verificadas.

14. Riscos e decisões abertas

14.1 Registro de riscos prioritários

ID	Risco	Impacto	Mitigação / decisão
R-01	Uso de fontes ou contatos sem base legal/termos adequados	Alto	Revisão jurídica por fonte e por canal antes da exportação
R-02	Associação de site incorreta a CNPJ	Alto	Revisão humana, score validado e evidências fortes
R-03	Supabase subdimensionado para staging nacional	Alto	Filtrar antes de persistir, teste de volume e orçamento
R-04	Scraper depender só de Playwright	Médio	Scrapy HTTP como padrão, browser seletivo
R-05	Acesso indevido por políticas ou chave de serviço	Alto	Schemas internos, grants, RLS, RBAC e testes negativos
R-06	Contatos de contabilidade classificados como farmácia	Alto	Heurística e revisão de contato compartilhado
R-07	Quebra silenciosa por mudança de HTML	Médio	Fixtures de contrato e alertas por preenchimento
R-08	Custos de ferramentas de busca e geocodificação	Médio	Orçamento, limites e validação de licenças
R-09	Perda de histórico comercial no reprocessamento	Alto	Separação física e teste de regressão
R-10	Backup apenas do banco, esquecendo Storage	Alto	Política independente de backup de objetos
R-11	Excesso de papéis e schemas antes do MVP	Médio	Implementar menor conjunto viável, mantendo fronteiras
R-12	Métricas de qualidade irreais sem baseline	Médio	Piloto, amostragem e calibração antes da expansão
R-13	Exigir base nacional permanente a partir do Google Maps	Alto	Usar Places apenas para descoberta/consulta permitida e manter Receita como universo mestre

ID	Risco	Impacto	Mitigação / decisão
R-14	Persistir/redistribuir dados Places sem permissão de armazenamento	Alto	Restrição técnica no pipeline, avaliação jurídica dos termos e teste de exportação
R-15	Interpretar dado público como permissão irrestrita de reutilização	Alto	Contrato/licença e finalidade revisados por fonte e por campo; negar por padrão
R-16	Atribuição incorreta de número de central a unidade de farmácia	Alto	Evidências por filial, classificação compartilhado e revisão humana
R-17	Misturar dados OSM sujeitos a ODbL com dataset proprietário sem avaliação	Alto	Segregação de origem, atribuição e avaliação de obrigações derivadas
R-18	Subestimar custo/benefício de fornecedores e APIs adicionais	Médio	Piloto incremental, monitoramento e teto por fonte

14.2 Registro de decisões (a aprovar)

ID	Questão e encaminhamento proposto	Status
D-01	Confirmar CNAEs 01/02/03; veterinárias 04 somente se aprovado	Pendente
D-02	Definir UF e municípios do piloto	Pendente
D-03	Definir quais canais o comercial pode usar e em que condições	Pendente
D-04	Definir orçamento e permissões de APIs de descoberta/validação	Pendente
D-05	Aprovar base legal, retenção, aviso de privacidade e responsável	Pendente
D-06	Selecionar plano/região de Supabase e limites de armazenamento/conexão	Pendente
D-07	Definir segregação por vendedor vs visibilidade global	Pendente
D-08	Decidir Metabase inicial, React próprio ou ambos	Pendente; este documento especifica React como alvo
D-09	Aprovar critérios amostrais de precisão e periodicidade de revalidação	Pendente
D-10	Confirmar CRM existente e estratégia de integração futura	Pendente

ID	Questão e encaminhamento proposto	Status
D-11	Definir RPO/RTO e backup de objetos do Storage	Pendente
D-12	Confirmar responsáveis por operação, incidentes e homologação	Pendente
D-13	Objetivo do Google é localizar farmácias e consultar contatos comerciais apresentados no Google Maps, não administrar fichas	**Definido pelo negócio**: usar Places API (New)
D-14	Validar termos, modelo de exibição, licença, API key, faturamento, FieldMask, orçamento e viabilidade da Places API no piloto	Pendente; bloqueia ativação da integração
D-15	Decidir se há necessidade futura de Places Insights/BigQuery no Brasil e cotar acesso	Pendente; evolução P2 opcional

D-16 | Aprovar fontes adicionais por fases: Farmácia Popular, Anvisa (consulta), sites/redes, OSM e fornecedores B2B; definir o que pode ser armazenado por fonte/campo | **Proposto; a liberação de cada fonte depende de aprovação individual** |
D-17 | Aprovar canal de registro de contato fornecido pela empresa e evidência mínima | Pendente |
D-18 | Escolher fontes complementares prioritárias com base no ganho real de contatos elegíveis por custo, e não na quantidade bruta de registros | Pendente após piloto |

15. Parecer técnico crítico sobre a arquitetura

15.1 Pontos fortes

1. **Separação entre cadastro mestre e enriquecimento.** O scraper não define sozinho o universo de farmácias, o que melhora mensuração de cobertura.
2. **CNPJ completo como identidade de estabelecimento.** Reduz fusões erradas entre unidades e redes.
3. **Procedência por campo.** Permite contestar um contato e explicar por que foi incluído.
4. **Workers independentes.** Evita acoplamento entre navegador, API e interface.
5. **PostgreSQL gerenciado no Supabase.** Reduz manutenção de infraestrutura, fornece ferramentas de autenticação e simplifica o início do produto.
6. **Separação da camada comercial.** Preserva status e histórico mesmo quando um coletor erra ou é reexecutado.

15.2 Pontos fracos e ajustes recomendados antes do código

1. **Fonte de descoberta insuficientemente comprovada.** A Receita não resolve, por si, qual é o domínio correto de cada farmácia. Este é potencialmente o maior gargalo de cobertura e deve ser testado com uma amostra antes de investir no dashboard.
2. **Risco de custo no Supabase.** Carregar o universo completo de CNPJs e HTML bruto no banco gerenciado pode custar muito mais do que manter somente o recorte farmacêutico e os dados consolidados. Exigir ensaio volumétrico.
3. **Pontuação de contatos não é verdade de campo.** DDD, MX e domínio vivo são evidências técnicas limitadas; sem validação humana por amostragem, score pode transmitir falsa confiança.
4. **Governança por canal ainda indefinida.** É inadequado liberar exportação integral de WhatsApp ou e-mails pessoais antes de decisões jurídicas e operacionais.
5. **Modelo de jobs e agendamentos precisa ser implementado com cuidado.** Um campo `status` não basta: precisa de reserva atômica, lease, heartbeat, limite de retentativas, idempotência e distinção entre acionamento manual e automático. Sem máquina ativa, a agenda não executará no horário previsto.
6. **Excesso de funcionalidade no MVP pode atrasar a prova de valor.** A prioridade deve ser uma UF piloto, uma fonte legalmente defensável e contatos medidos; mapa, integrações e CRM completo vêm depois.
7. **Risco de confundir serviço gerenciado com sistema completo.** Supabase não elimina trabalho de infraestrutura do crawler, monitoramento, retenção, segurança da API e backup dos objetos.
8. **O acúmulo de fontes não garante contatos válidos.** Fontes adicionais aumentam esforço de manutenção, resolução de conflitos, custo e exposição jurídica. A meta correta é contatos **novos e utilizáveis**, não números brutos somados de fornecedores.
9. **A descoberta pelo Google Maps não equivale a dados reutilizáveis para CRM.** Places permite localizar estabelecimentos e consultar detalhes, mas as regras de armazenamento e exportação impedem considerar seu conteúdo uma base permanente livre. Para prospecção nacional em escala, a Receita e fontes com reutilização autorizada continuam essenciais. O Places Insights pode aprimorar inteligência territorial, mas exige contrato e custos de BigQuery.

15.3 Recomendação de aprovação

Aprovável com ressalvas como arquitetura de referência, não como desenho completamente validado para produção nacional. Recomenda-se iniciar F0 e F1 imediatamente após as decisões mínimas de escopo e infraestrutura, mas **não escalar o scraping e não liberar exportações comerciais** sem validar fontes, associação site-CNPJ, políticas de canal, custos e testes de acesso. O marco de decisão mais importante é um piloto com dados reais, medição de qualidade e revisões documentadas.

16. Referências, rastreabilidade e histórico

16.1 Histórico de versões

Versão	Data	Alteração
1.0	23/10/2026	Especificação integrada inicial com Supabase, scraping e requisitos.
1.1	23/10/2026	Remoção da dependência de Docker e adoção de processos Python com `venv` e agendadores do sistema operacional.
1.2	23/10/2026	Definição de coletas manuais e automáticas, agendas no Supabase, endpoints, regras de concorrência, requisitos e testes.
1.3	23/10/2026	Inclusão condicional de Google Business Profile/Places, novos requisitos, controles de acesso, persistência, riscos, decisões, testes e desenho de integração.
1.4	23/10/2026	Objetivo confirmado: descoberta de farmácias e consulta de contatos no Google Maps via Places; removida gestão GBP do escopo, introduzidos endpoints, riscos, testes, diagrama e alternativa futura Places Insights.
1.5	23/10/2026	Arquitetura mult fontes: Farmácia Popular, Anvisa, sites, redes, OSM, fornecedores B2B e origem própria; matriz de permissão por campo; conectores, requisitos RF-059 a RF-072, testes TC-MF, novos riscos e decisões, diagrama e roteiro de validação.

16.2 Origem das decisões

A visão de base mestre da Receita, fontes de enriquecimento, CNAEs, score, procedência, supressão e seis fases foi preservada do documento de referência enviado pelo solicitante. As escolhas adicionais de schemas Supabase, estratégia de filtragem antes do PostgreSQL, contratos de API, requisitos numerados, papéis, segurança SSRF, plano de testes e critérios de aceite são **complementações propostas neste documento**, não fatos observados em implementação existente.

16.3 Documentação técnica e normativa consultada

- Receita Federal. Dicionário e layout dos dados públicos do CNPJ: https://www.gov.br/receitafederal/dados/cnpj-metadados.pdf

- IBGE/CONCLA. CNAE 4771-7/01 e classificações correlatas: https://concla.ibge.gov.br/busca-online-cnae.html?subclasse=4771701&tipo=cnae&versao=9&view=subclasse
- Supabase. Database Overview: https://supabase.com/docs/guides/database/overview
- Supabase. Connecting to Postgres: https://supabase.com/docs/guides/database/connecting-to-postgres
- Supabase. Securing Your API: https://supabase.com/docs/guides/api/securing-your-api
- Supabase. Storage Access Control: https://supabase.com/docs/guides/storage/security/access-control
- Supabase. Database Backups: https://supabase.com/docs/guides/platform/backups
- Scrapy. Job persistence: https://docs.scrapy.org/en/latest/topics/jobs.html
- Scrapy. AutoThrottle: https://docs.scrapy.org/en/latest/topics/autothrottle.html
- Google Maps Platform. Places API Policies: https://developers.google.com/maps/documentation/places/web-service/policies
- Google Maps Platform. Place IDs: https://developers.google.com/maps/documentation/places/web-service/place-id
- Google Places (New). Text Search: https://developers.google.com/maps/documentation/places/web-service/text-search
- Google Places (New). Nearby Search: https://developers.google.com/maps/documentation/places/web-service/nearby-search
- Google Places (New). FieldMask e cobrança: https://developers.google.com/maps/documentation/places/web-service/data-fields
- Google Places Insights. Descoberta de leads: https://developers.google.com/maps/architecture/places-insights-sales-leads
- Google Places Insights. Dados do Brasil: https://developers.google.com/maps/documentation/placesinsights/cloud-setup
- Ministério da Saúde. Lista de Farmácias Participantes do Farmácia Popular, versão 02/10/2026: https://www.gov.br/saude/pt-br/composicao/sectics/farmacia-popular/publicacoes/farmacias-participante-do-programa-farmacia-popular/view
- Anvisa. Consulta de Drogarias e Farmácias autorizadas: https://www.gov.br/anvisa/pt-br/sistemas/consulta-de-drogarias-e-farmacias
- OpenStreetMap. Copyright, ODbL, atribuição e regras de derivados: https://www.openstreetmap.org/copyright
- Receita Federal. Repositório de Dados Abertos da RFB: https://www.gov.br/receitafederal/dados
- ANPD. Guia Orientativo - Legítimo Interesse: https://www.gov.br/anpd/pt-br/centrais-de-conteudo/materiais-educativos-e-publicacoes/guia_orientativo_hipoteses_legais_tratamento_de_dados_pessoais_legitimo_interesse

Fim do documento.